

Modül 12 — Alıştırmalar

Çoklu Doğrusal Regresyon

Prof. Dr. Hakan Mehmetcik

2026-09-13

Bu Alıştırmalar Hakkında

Bu alıştırmalar **notlandırılmaz ve teslim edilmez**. Amacı, sınavdan önce kendi durumunuzu ölçebilmenizdir. Sınav soruları da bu biçimde (çoktan seçmeli, tek doğru cevap) kurgulanır.

Her soru 4 şıklıdır ve yalnızca **bir tanesi** doğrudur.

Cevaplarınızı not edin, sonra `12_modul_cevap_anahtari.qmd` dosyasıyla karşılaştırın.

Bölüm A — Çoklu Regresyona Giriş

1. Basit doğrusal regresyon ile çoklu doğrusal regresyon arasındaki temel fark nedir?

- a) Çoklu regresyonda bağımlı değişken sayısı birden fazladır
- b) Çoklu regresyonda birden fazla açıklayıcı (bağımsız) değişken aynı anda modele girer
- c) Çoklu regresyon yalnızca kategorik değişkenler için kullanılır
- d) Çoklu regresyonda R^2 hesaplanamaz

2. `price_twd_msq ~ n_convenience` modeli $R^2 = 0.326$, `price_twd_msq ~ dist_to_mrt_m` modeli $R^2 = 0.454$ veriyor. İkisini birlikte kullanan model $R^2 = 0.497$ veriyor. Bu artış hakkında ne söylenebilir?

- a) İki değişkeni birlikte kullanmak her zaman R^2 'yi ikisinin toplamı kadar artırır
- b) İki değişken, fiyat hakkında kısmen farklı/tamamlayıcı bilgi taşıyor; birlikte kullanmak ayrı ayrı kullanmaktan daha fazla varyans açıklıyor
- c) R^2 artışı yalnızca örneklem büyüklüğünün artmasından kaynaklanır
- d) Bu bir hesaplama hatasıdır, çünkü R^2 asla iki modelin ortalamasından büyük olamaz

Bölüm B — Paralel Eğimler Modeli

3. `lm(price_twd_msq ~ n_convenience + house_age_years + 0, data = df)` modelinde `+ 0` ne işe yarar?

- a) Modeli sıfırdan başlatarak eğimi sıfıra sabitler
- b) Genel bir kesme noktası yerine, her kategori (yaş grubu) için ayrı bir kesme noktası tahmin eder
- c) `n_convenience` değişkenini modelden çıkarır
- d) Modelin R^2 'sini sıfırlar

4. “Paralel eğimler modeli” adının nedeni nedir?

- a) Tüm gruplar için kesme noktası aynıdır
- b) Model yalnızca sürekli değişkenler için çalışır
- c) Her kategori için ayrı kesme noktası vardır ama açıklayıcı sürekli değişkenin eğimi tüm kategorilerde **aynı** kabul edilir
- d) Grafikte doğrular birbirini kesmek zorundadır

5. Paralel eğimler modelinde 0-15 yaş grubunun kesme noktası 9.41, `n_convenience` katsayısı 0.79’dur. Yakınında 4 market bulunan 0-15 yaş bir ev için tahmini `price_twd_msq` nedir?

- a) 9.41
- b) 12.57
- c) $0.79 \times 4 = 3.16$
- d) $9.41 - 0.79 \times 4$

6. Aynı modelde `n_convenience` katsayısı, tek başına kurulan `price_twd_msq ~ n_convenience` modelindeki katsayıya (0.80) çok yakındır (0.79). Bu ne anlama gelir?

- a) Model yanlış kurulmuştur
- b) `n_convenience` ile `house_age_years` arasında güçlü bir ilişki yoktur; bu yüzden yaş grubunu modele eklemek `n_convenience`’in etkisini pek değiştirmemiştir
- c) `house_age_years` fiyatla hiç ilişkili değildir
- d) Model, `house_age_years`’ı görmezden gelmiştir

Bölüm C — Çoklu Doğrusallık ve VIF

7. `n_convenience` ile `dist_to_mrt_m` arasındaki korelasyon $r \approx -0.60$ bulunmuştur. Bu iki değişkeni birlikte modele koyduğunuzda ne beklenir?

- a) Hiçbir şey değişmez, korelasyon regresyonu etkilemez
- b) Her iki değişkenin katsayısı, tek başına kullanıldıklarındaki değerden farklılaşabilir çünkü

- artık birbirlerinin taşıdığı bilgiyi paylaşıyorlar
c) Model otomatik olarak hata verir ve çalışmaz
d) R^2 mutlaka düşer

8. VIF (Varyans Şişirme Faktörü) neyi ölçer?

- a) Bağımlı değişkenin varyansını
b) Bir açıklayıcı değişkenin, modeldeki diğer açıklayıcı değişkenler tarafından ne kadar açıklandığını; yüksek VIF, o değişkenin katsayı tahmininin ne kadar kararsızlaştığını gösterir
c) Modelin genel anlamlılığını (F-testi)
d) Artıkların normal dağılıp dağılmadığını

9. `vif(md1_2cont)` çıktısı her iki değişken için de 1.57 vermiştir. Bu değer hakkında ne söylenebilir?

- a) Ciddi bir çoklu doğrusallık sorunu vardır ($VIF > 10$)
b) Dikkat edilmesi gereken orta düzey bir sorun vardır ($VIF > 5$)
c) Genel kabul gören eşiklerin (5 ve 10) altındadır; iki değişkeni birlikte kullanmak güvenlidir
d) VIF değeri 1'in altında olmalıydı, bu nedenle hesaplama hatalıdır

10. Aşağıdakilerden hangisi doğrudur?

- a) İki değişken arasında herhangi bir korelasyon varsa, onları asla aynı modelde kullanmamak gerekir
b) Korelasyon var olması otomatik olarak ciddi çoklu doğrusallık anlamına gelmez; asıl ölçüt VIF'tir
c) VIF yalnızca kategorik değişkenler için hesaplanabilir
d) Çoklu doğrusallık yalnızca $R^2 = 1$ olduğunda ortaya çıkar

Bölüm D — Kategorik Değişkenler ve Dummy Kodlama

11. Bir kategorik değişken (örn. `Species`, 4 kategori) neden regresyon denkleminde doğrudan sayısal bir değişken gibi eklenemez?

- a) R bunu teknik olarak hiç kabul etmez
b) Kategoriler arasında sıralı/sayısal bir mesafe anlamı yoktur; model bunu sayı olarak yorumlarsa anlamsız bir eğim üretir
c) Kategorik değişkenler her zaman ikiden fazla düzeye sahiptir
d) Kategorik değişkenler yalnızca `ggplot()` içinde kullanılabilir

12. `lm(Weight ~ Species, data = fish)` (kesme noktalı, referans kategorili) modelinde `Species` için raporlanan katsayılar neyi ifade eder?

- a) Her türün mutlak ortalama ağırlığını
- b) Referans alınan türe (genelde alfabetik ilk kategori) göre **farki**
- c) Türlerin veri setindeki gözlem sayısını
- d) Türler arasındaki korelasyonu

13. `lm(Weight ~ Species + 0, data = fish)` modelinde (sıfır kesişimli) katsayılar neyi ifade eder?

- a) Yine referans kategoriye göre farkı
- b) Her türün **doğrudan** tahmini ortalama ağırlığını
- c) Türler arası korelasyonu
- d) Hiçbir şey; `+ 0` model hatasına yol açar

14. Ders notundaki balık verisinde **SpeciesBream** katsayısı (kesme noktalı modelde) negatif ağırlıklar üretmesine neden olan sorun neydi?

- a) Veri setinde eksik gözlem vardı
- b) Referans tür (Bream) kesme noktası olarak alınıp diğer türler ona göre fark olarak raporlandığında, bazı farkların Bream'in ağırlığından büyük çıkması negatif toplam ağırlık gibi görünen anlamsız bir sonuç doğurdu
- c) `lm()` fonksiyonu kategorik değişkenlerle çalışmaz
- d) Veri setinde yalnızca bir tür vardı

Bölüm E — Model Karşılaştırma ve Tahmin

15. Aynı veri setinde kurulan iki modelin Adjusted R^2 değerleri karşılaştırıldığında hangisi tercih edilir (diğer koşullar eşitken)?

- a) Daha düşük Adjusted R^2 'ye sahip olan
- b) Daha yüksek Adjusted R^2 'ye sahip olan
- c) Adjusted R^2 model seçiminde kullanılmaz
- d) İkisi arasında fark yoktur, her zaman aynıdır

16. `predict mdl_both, newdata = data.frame(n_convenience = 8, house_age_years = "15 to 30"))` komutu ne yapar?

- a) Modeldeki tüm katsayıları sıfırlar
- b) Verilen `n_convenience` ve `house_age_years` değerleri için modelin fiyat tahminini hesaplar
- c) Yalnızca `house_age_years` değişkenini kullanarak tahmin yapar, `n_convenience`'i göz ardı eder
- d) Yeni bir model kurar

17. Çoklu regresyonun temel avantajı basit regresyona göre nedir?

- a) Her zaman daha yüksek bir R^2 garanti eder
- b) Birden fazla açıklayıcı faktörü aynı anda hesaba katarak, tek bir değişkenin tek başına verdiğinden daha bütüncül bir tahmin/yorum sunar
- c) Kategorik değişkenlerle asla kullanılamaz
- d) Hesaplaması basit regresyondan daha kolaydır

18. Paralel eğimler modelinde `n_convenience`'ın eğiminin her yaş grubunda **aynı** olduğu varsayımı gerçekte doğru olmayabilir. Ders notunda bu varsayım nasıl sınanmıştır?

- a) Sınanmamıştır, varsayım olduğu gibi kabul edilmiştir
- b) `n_convenience * house_age_years` etkileşim modeli kurulup paralel eğimler modeliyle `anova()` ile karşılaştırılmıştır
- c) Yalnızca grafiğe bakılarak karar verilmiştir
- d) VIF hesaplanarak sınanmıştır

Bölüm F — Etkileşim, Referans Kategori ve Standartlaştırma

19. Ders notundaki etkileşim modeli karşılaştırmasında F-testi $p \approx 0.36$ çıkmıştır. Bu ne anlama gelir?

- a) Etkileşim modeli kesinlikle yanlıştır
- b) Etkileşim terimlerinin eklenmesi, modelin açıklayıcılığını istatistiksel olarak anlamlı biçimde artırmamıştır; daha basit paralel eğimler modeli tercih edilebilir
- c) Paralel eğimler modeli artık kullanılamaz
- d) p -değeri regresyonda hesaplanamaz

20. `lm(price_twd_msq ~ house_age_years, data = df)` (kesme noktalı, + 0 olmadan) modelinde `house_age_years15 to 30` katsayısı -2.76 bulunmuştur. Bu sayı ne ifade eder?

- a) 15-30 yaş evlerin ortalama fiyatının -2.76 TWD/m² olduğunu
- b) 15-30 yaş evlerin, referans kategori olan 0-15 yaş evlere kıyasla metrekarede ortalama 2.76 TWD daha ucuz olduğunu
- c) Modelin hatalı kurulduğunu, çünkü fiyat negatif olamaz
- d) İki grup arasında hiçbir fark olmadığını

21. `n_convenience` ve `dist_to_mrt_m` değişkenleri `scale()` ile standartlaştırıldıktan sonra kurulan modelde katsayılar sırasıyla 1.07 ve -2.13 bulunmuştur. Bu neden ham (standartlaştırılmamış) katsayılardan (0.36 ve -0.0017) daha kullanışlı bir karşılaştırmadır?

- a) Standartlaştırılmış katsayılar her zaman ham katsayılardan büyük çıkar
- b) İki değişken çok farklı ölçeklerde (market sayısı vs. metre) olduğundan, ham katsayıları doğrudan karşılaştırmak yanıltıcıdır; standartlaştırma her ikisini de “1 standart sapmalık değişimin etkisi” ortak birimine getirir

- c) Standartlaştırma yalnızca kategorik değişkenler için gereklidir
- d) Ham katsayılar R^2 'yi değiştirdiği için kullanılamaz