

Modül 12: Çoklu Doğrusal Regresyon

Prof. Dr. Hakan Mehmetcik

2026-09-13

Regresyonda Devam: Çoklu Doğrusal Regresyon

Hatırlayalım: Regresyon Analizi Nedir?

Regresyon analizi, bir **bağımlı değişken** ile bir veya daha fazla **bağımsız değişken** arasındaki ilişkiyi incelemek ve bu ilişkiyi bir matematiksel modelle açıklamak için kullanılan bir istatistiksel yöntemdir. Temel amacı, bağımlı değişkenin değerini tahmin etmek veya bağımsız değişkenlerin bağımlı değişken üzerindeki etkisini değerlendirmektir.

Doğrusal (Linear) Regresyon Nedir?

Doğrusal regresyon, bağımlı değişken ile bağımsız değişken(ler) arasındaki ilişkinin doğrusal olduğunu varsayar. Matematiksel olarak model:

$$Y = \beta_0 + \beta_1 X + \epsilon$$

şeklinde ifade edilir. Burada:

- Y : Bağımlı değişken
- X : Bağımsız değişken
- β_0 : Kesme noktası (Intercept, $X = 0$ olduğunda Y 'nin değeri)
- β_1 : Eğim katsayısı (Bağımsız değişkende bir birimlik değişiklik olduğunda Y 'deki değişim)
- ϵ : Hata terimi (modelin açıklayamadığı rastgele değişkenlik)

i R'da Doğrusal Regresyon

R'da doğrusal regresyon yapmak için `lm()` fonksiyonu kullanılır.

```
# Modeli tanımlama
model <- lm(Y ~ X, data = dataset)

# Model özetini görüntüleme
summary(model)
```

`summary()` Fonksiyonunun Ürettiği Sonuçlar

1. Call:

- Modelin formülü ve kullanılan veri seti hakkında bilgi verir.

2. Residuals (artıklar):

- Modeldeki artıkların (gözlenen – tahmin edilen değer) özet istatistiklerini (min, 1. çeyrek, medyan, 3. çeyrek, max) gösterir. Artıkların küçük ve dengeli dağılması modelin iyi bir uyum sağladığını gösterir.

3. Coefficients (Katsayılar):

- **Estimate:** Her bir değişken için tahmini katsayıyı gösterir.
 - **Intercept** (β_0): Bağımlı değişkenin $X = 0$ olduğundaki tahmini değeri.
 - **Slope** (β_1): Bağımsız değişkende bir birimlik artış olduğunda bağımlı değişkendeki tahmini değişim.
- **Std. Error:** Tahminlerin standart hatası.
- **t value:** Katsayıların 0'dan farklı olup olmadığını test eden t-istatistiği.
- **Pr(>|t|):** Katsayının anlamlı olup olmadığını belirten p-değeri (<0.05 ise anlamlıdır).

4. Residual Standard Error (Artıkların Standart Hatası):

- Modelin artıklarının standart sapmasını ifade eder. Daha düşük bir değer daha iyi bir uyum anlamına gelir.

5. R-squared (R^2):

- Bağımlı değişkenin toplam varyansının ne kadarının model tarafından açıklandığını gösterir. 1'e yakın bir değer modelin iyi bir uyum sağladığını ifade eder.

6. Adjusted R-squared:

- R^2 'nin düzeltilmiş hali. Özellikle çoklu bağımsız değişkenler olduğunda daha güvenilir bir ölçüttür.

7. F-statistic:

- Modelin genel anlamlılığını test eder. P-değeri <0.05 ise model genel olarak anlamlıdır.

Bu oturumda regresyon üzerine farklı örnekler yapacağız. Ancak her bir örnekte, veri setine yönelik farklı soruların cevaplarını da araştıracağız. Bu yöntemle, şimdiye kadar öğrendiğimiz çeşitli teknik ve analizleri regresyon analiziyle birleştirmiş olacağız. Ayrıca, bu oturumun bir diğer konu başlığı, kategorik değişkenlerin regresyon analizinde nasıl kullanılacağı olacak.

Örnek 1:

Bu alıştırma için, dünya rekoru kırılan atletizm (örneğin 100 metre koşu) ve saha (örneğin gülle atma) etkinliklerinin dünya rekor sürelerini ve mesafelerini içeren bir veri setimiz var. Bu veri seti, rekoru kıran kişi, milliyeti, rekorun kırıldığı yer ve kırıldığı yıl gibi bilgileri içeriyor. Unutmayın ki tüm dünya rekorları Olimpiyatlarda kırılmamıştır; birçok rekor bölgesel veya ulusal yarışmalarda gerçekleşmiştir.

```
# gerekli paketler  
library(dplyr)
```

Attaching package: 'dplyr'

The following objects are masked from 'package:stats':

filter, lag

The following objects are masked from 'package:base':

intersect, setdiff, setequal, union

```
library(ggplot2)  
library(readr)  
library(here)
```

here() starts at /Users/kobain/Dersler/IST2083

```
# veri setini R'a ekle
wr <- read_csv(here("data", "worldrecord.csv"))
```

New names:

```
* `` -> `...1`
```

Rows: 285 Columns: 8

-- Column specification -----

Delimiter: ","

chr (5): Event, Type, Athlete, Nationality, Location

dbl (3): ...1, Record, Year

i Use `spec()` to retrieve the full column specification for this data.

i Specify the column types or set `show\_col\_types = FALSE` to quiet this message.

Veriyi İnceleme

Soru 1:

Veri setinde kaç farklı etkinlik türü (“Erkekler 100m”, “Kadınlar gülle atma” vb.) bulunmaktadır?

```
# Kaç farklı etkinlik olduğunu görmek için
wr %>%
  count(Event) %>%
  arrange(desc(n))
```

Event	n
Mens Polevault	55
Womens Shotput	41
Mens Shotput	39
Mens Mile	32
Womens 800m	29
Mens TripleJump	25
Mens 800m	24
Mens 100m	17
Womens Mile	13
Womens 100m	10

Soru 2:

Usain Bolt erkekler 100 metre koşusunda ilk dünya rekorunu hangi yıl kırdı?

```
wr %>%
  filter(Athlete == "Usain Bolt") %>%
  select(Event, Year, Record)
```

Event	Year	Record
Mens 100m	2008	9.72
Mens 100m	2008	9.69
Mens 100m	2009	9.58

Soru 3:

Kadınlar 1 mil dünya rekorunu 260 saniyenin altında bir sürede ilk kez kıran kadın kimdi?

```
wr %>%
  filter(Event == "Womens Mile", Record < 260) %>%
  arrange(Year) %>%
  slice(1)
```

...1	Event	Type	Record	Athlete	Nationality	Location	Year
146	Womens Mile	time	258.1	Mary Slaney	United States	Paris	1982

Soru 4:

Rekoru belirleyen süre veya mesafeyi hangi değişken gösteriyor? Bu değişkenin türü nedir?

```
wr %>%
  glimpse()
```

Rows: 285

Columns: 8

```
$ ...1      <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, ~
$ Event     <chr> "Mens 100m", "Mens 100m", "Mens 100m", "Mens 100m", "Mens ~
$ Type      <chr> "time", "time", "time", "time", "time", "time", "time", "t~
$ Record    <dbl> 10.06, 10.03, 10.02, 9.95, 9.93, 9.92, 9.90, 9.86, 9.85, 9~
```

```
$ Athlete      <chr> "Bob Hayes", "Jim Hines", "Charles Greene", "Jim Hines", "~
$ Nationality  <chr> "United States", "United States", "United States", "United~
$ Location     <chr> "Tokyo, Japan", "Sacramento, USA", "Mexico City, Mexico", ~
$ Year         <dbl> 1964, 1968, 1968, 1968, 1983, 1988, 1991, 1991, 1994, 1996~
```

Soru 5:


Kadınlar ve erkekler için gülle atma rekoru mesafesi ile yıl arasındaki dağılımı gösteren bir scatterplot (dağılım grafiği) oluşturalım. Neden?

Cevap: Scatterplot, bu iki sayısal değişken arasında doğrusal bir ilişki olup olmadığını görmemizi sağlar.

Erkekler için gülle atma rekoru ile yıl arasındaki ilişkiyi gösteren scatterplot

```
mens_shotput <- wr %>%
  filter(Event == "Mens Shotput")


mens_shotput %>%
  ggplot(aes(x = Year, y = Record)) +
  geom_point() +
  labs(title = "Erkekler Gülle Atma Rekoru", x = "Yıl", y = "Mesafe (metre)") +
  theme_minimal()
```



Kadınlar için gülle atma rekoru ile yıl arasındaki ilişkiyi gösteren scatterplo

```
womens_shotput <- wr %>%
  filter(Event == "Womens Shotput")

womens_shotput %>%
  ggplot(aes(x = Year, y = Record)) +
  geom_point() +
  labs(title = "Kadınlar Gülle Atma Rekoru", x = "Yıl", y = "Mesafe (metre)") +
  theme_minimal()
```



Scatterplot Analizi: Erkekler ve kadınlar için rekor mesafesi ile yıl arasında pozitif doğrusal bir ilişki görülmektedir.

Soru 7:

Bu gülle atma dünya rekoru verilerine bir doğrusal model (linear model) oluşturduğumuzda neyi belirleyebiliriz? Erkekler için dünya rekoru mesafesini tahmin eden model denklemini nedir?

```
lm_md1_men <- lm(Record~Year, data = mens_shotput)
summary(lm_md1_men)
```

```
Call:
lm(formula = Record ~ Year, data = mens_shotput)

Residuals:
    Min       1Q   Median       3Q      Max
-0.5718 -0.2851 -0.1659  0.2096  1.3389

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -2.433e+02  1.084e+01  -22.45  <2e-16 ***
Year          1.341e-01  5.515e-03   24.32  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.4499 on 37 degrees of freedom
Multiple R-squared:  0.9411,    Adjusted R-squared:  0.9395
F-statistic: 591.2 on 1 and 37 DF,  p-value: < 2.2e-16
```

Intercept Yorumlaması: Yıl sıfırdan başlamadığı için intercept (kesişme noktası) anlamlı değildir.

```
mens_shotput <- mens_shotput %>%
  mutate(Year = Year - min(Year)) # Yılı sıfırdan başlatma

lm_mdl_men <- lm(Record ~ Year, data = mens_shotput)
summary(lm_mdl_men)
```

```
Call:
lm(formula = Record ~ Year, data = mens_shotput)

Residuals:
    Min       1Q   Median       3Q      Max
-0.5718 -0.2851 -0.1659  0.2096  1.3389

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 17.901305   0.118691  150.82  <2e-16 ***
Year          0.134107   0.005515   24.32  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 0.4499 on 37 degrees of freedom
Multiple R-squared: 0.9411, Adjusted R-squared: 0.9395
F-statistic: 591.2 on 1 and 37 DF, p-value: < 2.2e-16

Kadınlar için dünya rekoru mesafesini tahmin eden model denklemini nedir?

```
womens_shotput <- womens_shotput %>%  
  mutate(Year = Year - min(Year)) # Yılı sıfırdan başlatma  
  
lm_md1_women <- lm(Record ~ Year, data = womens_shotput)  
summary(lm_md1_women)
```

Call:

```
lm(formula = Record ~ Year, data = womens_shotput)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-1.34968	-0.24704	0.09981	0.35615	0.70689

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	14.837040	0.157671	94.10	<2e-16 ***
Year	0.233657	0.007409	31.54	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5061 on 39 degrees of freedom

Multiple R-squared: 0.9623, Adjusted R-squared: 0.9613

F-statistic: 994.6 on 1 and 39 DF, p-value: < 2.2e-16

Sonuç

Erkekler ve kadınlar gülle atma dünya rekorları için dağılım grafikleri, bu etkinliklerin yıllar boyunca güçlü ve pozitif bir doğrusal ilişki gösterdiğini ortaya koymaktadır. Erkeklerde rekor mesafesi yılda ortalama 0.13 metre, kadınlarda ise 0.23 metre artmaktadır. Ancak, başlangıç yılına bağlı olan intercept (kesişme noktası), sorunun bağlamına göre doğrudan yorumlanamaz. Bu nedenle, yılı yeniden düzenleyerek modeller oluşturulmuş ve verilerle iyi bir uyum gösterilmiştir. Fakat çarpıcı bir biçimde, modelimize göre kadınlar için yıllık değişim oranı erkeklere göre daha büyüktür ve bu sonuç istatistiksel olarak anlamlıdır.

Örnek 2:

Araştırma Sorusu: *“Erkekler ve kadınlar için 1 mil dünya rekoru süreleri yıllar içinde nasıl değişti?”*

Soru 1: Veri modeline geçmeden önce ilk ne yapılmalı?

Cevap: İlgi duyulan iki değişkenin scatterplot’unu (dağılım grafiği) oluşturun.

Soru 2: Bir doğrusal modelde, bağımlı değişkendeki varyansın ne kadarı bağımsız değişkenle açıklanabilir?


Cevap: R-kare değeri bu bilgiyi verir.

Soru 3: Hangi scatterplot daha güçlü bir doğrusal ilişki gösteriyor?


```
# Erkekler ve kadınlar için veri alt kümeleri
mens_mile <- wr %>% filter(Event == "Mens Mile")
womens_mile <- wr %>% filter(Event == "Womens Mile")

# Erkekler için scatterplot
mens_mile %>%
  ggplot(aes(x = Year, y = Record)) +
  geom_point() +
  labs(title = "Erkekler 1 Mil Dünya Rekoru", x = "Yıl", y = "Süre (saniye)") +
  theme_minimal()
```

Erkekler 1 Mil Dünya Rekoru



```
# Kadınlar için scatterplot
womens_mile %>%
  ggplot(aes(x = Year, y = Record)) +
  geom_point() +
  labs(title = "Kadınlar 1 Mil Dünya Rekoru", x = "Yıl", y = "Süre (saniye)") +
  theme_minimal()
```



Soru 4: Erkekler için dünya rekoru süresi her yıl ortalama kaç saniye azalıyor?

```
men_model <- lm(Record ~ Year, data = mens_mile)
summary(men_model)
```

Call:

```
lm(formula = Record ~ Year, data = mens_mile)
```

Residuals:

Min	1Q	Median	3Q	Max
-2.6033	-0.7175	-0.1860	0.7278	2.8533

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1007.47075	21.35031	47.19	<2e-16 ***
Year	-0.39347	0.01091	-36.07	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.371 on 30 degrees of freedom

Multiple R-squared: 0.9775, Adjusted R-squared: 0.9767

F-statistic: 1301 on 1 and 30 DF, p-value: < 2.2e-16

Soru 5: Kadınlar için dünya rekoru süresi her yıl ortalama kaç saniye azalıyor?

```
women_model <- lm(Record ~ Year, data = womens_mile)
summary(women_model)
```

Call:

```
lm(formula = Record ~ Year, data = womens_mile)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.635	-1.853	-1.107	1.376	5.186

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2189.2834	198.2509	11.043	2.72e-07 ***
Year	-0.9729	0.1002	-9.713	9.88e-07 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.824 on 11 degrees of freedom

Multiple R-squared: 0.8956, Adjusted R-squared: 0.8861

F-statistic: 94.35 on 1 and 11 DF, p-value: 9.88e-07

Soru 6: Erkeklerin rekor süresinin 1 saniye azalması için kaç yıl geçmesi gerekir?

```
1 / abs(coef(men_model)["Year"])
```

Year
2.541472

Soru 7: Kadınların rekor süresinin 1 saniye azalması için kaç yıl geçmesi gerekir?

```
1 / abs(coef(women_model)["Year"])
```

Year
1.027876

Soru 8: Erkekler ve kadınlar için dünya rekoru sürelerinin varyansının ne kadarı yıl ile açıklanabilir?

Cevap:

- Erkekler: Adjusted R-squared: 0.9767
- Kadınlar: Adjusted R-squared: 0.8861

Çıkarım:

Erkekler ve kadınlar için 1 mil dünya rekoru etkinliklerine ait scatterplot'lara (dağılım grafikleri) bakıldığında, her iki etkinliğin de zamanla güçlü ve negatif bir ilişki izlediği görülmektedir. Her iki grup için de doğrusal (lineer) ilişki varsayımı sağlanmış görünmektedir.

- Erkekler için 1 mil dünya rekoru süresi yılda ortalama 0.393 saniye azalırken, kadınlar için bu süre yılda ortalama 0.976 saniye azalmaktadır.
- **Kesişme noktası (intercept)** tahmini, yıl sıfıra eşit olduğunda rekor süresinin değerini ifade ettiğinden, bu bağlamda yorumlanamaz.

Her iki lineer model de verilere iyi bir uyum sağlamaktadır:

- Erkekler için **R-kare değeri** 0.976'dır, yani performanstaki değişimin %97.7'si yıl değişkeniyle açıklanabilmektedir.
- Kadınlar için **R-kare değeri** 0.886'dır, yani performanstaki değişimin %88.6'sı yıl değişkeniyle açıklanabilmektedir.

Bu analiz, erkekler ve kadınlar için dünya rekoru sürelerinin son birkaç on yılda doğrusal olarak azaldığını ortaya koymaktadır.

Örnek 3:

Dünya Rekoru Verileriyle Çalışmaya Devam Ediyoruz: Şimdi, 1970'ten itibaren erkekler sırkla atlama dünya rekorları için en iyi uyum sağlayan doğrusal modeli bulmak istiyoruz.

Adım 1: İlk olarak, 1970 ve sonrası yıllarda erkekler sırkla atlama etkinliğindeki dünya rekorlarını içeren bir veri çerçevesi oluşturalım.

```
menspole <- wr %>%  
  filter(Event == "Mens Polevault" & Year >= 1970)
```

Soru 1: Erkekler sırkla atlamadaki güncel dünya rekoru yüksekliği (metre cinsinden) nedir?

```
max_record <- menspole %>%
  summarise(Max_Record = max(Record))
max_record
```

Max_Record
6.14

Soru 2: Sırıkla atlama rekoru ilk kez 6 metreyi hangi yıl geçti?

```
menspole %>%
  filter(Record > 6)
```


...1	Event	Type	Record	Athlete	Nationality	Location	Year
194	Mens Polevault	distance	6.01	Sergey Bubka	Soviet Union	Moscow, Soviet Union	1986
195	Mens Polevault	distance	6.03	Sergey Bubka	Soviet Union	Prague, Czechoslovakia	1987
196	Mens Polevault	distance	6.05	Sergey Bubka	Soviet Union	Bratislava, Czechoslovakia	1988
197	Mens Polevault	distance	6.06	Sergey Bubka	Soviet Union	Nice, France	1988
198	Mens Polevault	distance	6.07	Sergey Bubka	Soviet Union	Shizuoka, Japan	1991
199	Mens Polevault	distance	6.08	Sergey Bubka	Soviet Union	Moscow, Soviet Union	1991
200	Mens Polevault	distance	6.09	Sergey Bubka	Soviet Union	Formia, Italy	1991
201	Mens Polevault	distance	6.10	Sergey Bubka	Soviet Union	Malmö, Sweden	1991
202	Mens Polevault	distance	6.11	Sergey Bubka	Ukraine	Dijon, France	1992
203	Mens Polevault	distance	6.12	Sergey Bubka	Ukraine	Padua, Italy	1992
204	Mens Polevault	distance	6.13	Sergey Bubka	Ukraine	Tokyo, Japan	1992
205	Mens Polevault	distance	6.14	Sergey Bubka	Ukraine	Sestriere, Italy	1994

Soru 3: 1970'ten itibaren erkekler sıırıkla atlama rekorlarını yıl fonksiyonu olarak gösteren bir scatterplot oluşturun ve verilere doğrusal bir model uydurun.

```
# Lineer modeli oluşturma
men_md1_pole <- lm(Record ~ Year, data = menspole)

# Scatterplot ve modelin çizimi
menspole %>%
  ggplot(aes(x = Year, y = Record)) +
  geom_point(color = "blue") +
  geom_smooth(method = "lm", se = FALSE, color = "red") +
  labs(
    title = "1970'ten İtibaren Erkekler Sırıkla Atlama Dünya Rekorları",
    x = "Yıl",
    y = "Rekor Yüksekliği (metre)"
  ) +
  theme_minimal()
```

`geom\_smooth()` using formula = 'y ~ x'



Soru 4: Rekorun değişimini en iyi şekilde ne açıklar?

Cevap: Dağılım grafiğinde açıkça görüldüğü üzere, sıırıkla atlama rekor yüksekliği zamanla sürekli artmıştır. Bunun için rekoru yıl (zaman) bağlamında değerlendirmek (bir model oluşturmak) mantıklı olacaktır.

Soru 5: 1970'ten itibaren erkekler sırkla atlama dünya rekorunun değişimini tanımlayan doğrusal model için katsayı tahminlerini rapor edin.

```
summary(men_md1_pole)
```

Call:

```
lm(formula = Record ~ Year, data = menspole)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.058171	-0.028171	-0.005313	0.015400	0.084687

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-5.185e+01	1.625e+00	-31.91	<2e-16 ***
Year	2.911e-02	8.199e-04	35.50	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.0356 on 35 degrees of freedom

Multiple R-squared: 0.973, Adjusted R-squared: 0.9722

F-statistic: 1260 on 1 and 35 DF, p-value: < 2.2e-16

Intercept'in negatif olması, yıl değişkeninin başlangıç noktasının modele uygun olmadığını gösterir. Bu nedenle, yılı transpoze ederek modeli tekrar oluşturabiliriz. Yıl değişkenini 1970'ten başlayacak şekilde yeniden düzenleyelim ve ardından doğrusal modeli tekrar çalıştıralım.

```
# Yılı transpoze et
menspole <- menspole %>%
  mutate(Year_Transposed = Year - 1970)

# Yeni model oluştur
men_md1_pole_transposed <- lm(Record ~ Year_Transposed, data = menspole)

# Modelin özetini incele
summary(men_md1_pole_transposed)
```

Call:

```
lm(formula = Record ~ Year_Transposed, data = menspole)
```

Residuals:

Min	1Q	Median	3Q	Max
-0.058171	-0.028171	-0.005313	0.015400	0.084687

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	5.4870986	0.0115819	473.8	<2e-16 ***
Year_Transposed	0.0291072	0.0008199	35.5	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.0356 on 35 degrees of freedom

Multiple R-squared: 0.973, Adjusted R-squared: 0.9722

F-statistic: 1260 on 1 and 35 DF, p-value: < 2.2e-16

Modelin Yorumu:

1. Kesme Noktası (Intercept):

- **Değer:** 5.4871
- Bu değer, **1970 yılında erkekler sırikla atlama dünya rekorunun** yüksekliğini temsil eder ve anlamlı bir sonuçtur.
- 1970 yılında dünya rekoru yaklaşık **5.49 metre** olarak tahmin edilmiştir.

2. Eğim (Slope):

- **Değer:** 0.0291
- Bu katsayı, **1970'ten sonra geçen her yıl için sırikla atlama dünya rekorunun ortalama 0.029 metre (yaklaşık 2.91 cm) arttığını** ifade eder.
- Bu artış oranı, rekorların zamanla düzenli bir şekilde geliştiğini göstermektedir.

3. Model Uyumunun Gücü (R-squared):

- **Multiple R-squared:** 0.973
- **Adjusted R-squared:** 0.9722
- Model, rekor yüksekliğindeki varyansın %97.3'ünü açıklamaktadır. Bu da modelin oldukça güçlü bir uyum sağladığını gösterir.

4. F-Testi ve p-Değeri:

- **F-statistic:** 1260
- **p-value:** $< 2.2e-16$
- Modelin geneli istatistiksel olarak anlamlıdır. Bu, “Yıl” değişkeninin rekor yüksekliğini açıklamada önemli bir faktör olduğunu ifade eder.

Kategorik Açıklayıcı Değişkenler

Kategorik değişkenler, regresyon analizinde özel bir dikkat gerektirir. Bu değişkenler, sürekli ya da iki kategorili değişkenler gibi doğrudan regresyon denklemine eklenemez. Bunun yerine, regresyon modeline dahil edilebilmeleri için farklı bir kodlama sistemi kullanılarak bir dizi değişkene dönüştürülmeleri gerekir. Kodlama sistemleri farklı olabilir, ancak seçilen kodlama sistemi değişkenin genel etkisini değiştirmez.

Örnek 4:


Balık veri seti, yedi yaygın balık türünü ve bu balıkların ağırlıkları gibi bilgilerle bir tahmin modeli geliştirmek için kullanılabilir. Amaç, balık türlerine göre ağırlık tahmini yapmaktır.

```
fish <- read.csv(here("data", "Fish.csv"))
species <- c("Bream", "Perch", "Pike", "Roach")
fish <- fish[fish$Species %in% species,]
head(fish)
```

Species	Weight	Length1	Length2	Length3	Height	Width
Bream	242	23.2	25.4	30.0	11.5200	4.0200
Bream	290	24.0	26.3	31.2	12.4800	4.3056
Bream	340	23.9	26.5	31.1	12.3778	4.6961
Bream	363	26.3	29.0	33.5	12.7300	4.4555
Bream	430	26.5	29.0	34.0	12.4440	5.1340
Bream	450	26.8	29.7	34.7	13.6024	4.9274

Soru 1: Dağılım Grafiği Oluşturma

```
ggplot(data = fish, aes(x = Weight)) +
  geom_histogram(bins = 9, fill = "skyblue", color = "black") +
  facet_wrap(~Species) +
  labs(title = "Balık Türlerine Göre Ağırlık Dağılımı",
       x = "Ağırlık (gram)", y = "Frekans") +
  theme_minimal()
```



Soru 2: Türlerle Göre Ortalama Ağırlık

```
fish |>
  group_by(Species) |>
  summarise(mean_weight = mean(Weight, na.rm = TRUE)) |>
  arrange(desc(mean_weight))
```

Species	mean_weight
Pike	718.7059
Bream	617.8286
Perch	382.2393
Roach	152.0500

Soru 3: Türlerle Göre Ağırlık Değişimini Açıklayan Modelin Katsayıları

```
model_with_intercept <- lm(Weight ~ Species, data = fish)
summary(model_with_intercept)
```

Call:

```
lm(formula = Weight ~ Species, data = fish)
```

Residuals:

Min	1Q	Median	3Q	Max
-518.71	-239.74	-78.14	133.31	931.29

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	617.83	53.00	11.657	< 2e-16 ***
SpeciesPerch	-235.59	67.56	-3.487	0.000676 ***
SpeciesPike	100.88	92.69	1.088	0.278579
SpeciesRoach	-465.78	87.89	-5.300	5.13e-07 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 313.6 on 124 degrees of freedom

Multiple R-squared: 0.2581, Adjusted R-squared: 0.2402

F-statistic: 14.38 on 3 and 124 DF, p-value: 4.231e-08

Soru 4: Modelin Problemi

Bu modelde, intercept değeri **Bream** türü için raporlanmıştır ve diğer türler için negatif ağırlık değerleri üretmektedir. Bu durum anlamlı değildir. Çözüm bir sıfır kesişimli model üretmektir:

```
model_no_intercept <- lm(Weight ~ Species + 0, data = fish)
summary(model_no_intercept)
```

Call:

```
lm(formula = Weight ~ Species + 0, data = fish)
```

Residuals:

Min	1Q	Median	3Q	Max
-----	----	--------	----	-----

-518.71 -239.74 -78.14 133.31 931.29

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
SpeciesBream	617.83	53.00	11.657	< 2e-16 ***
SpeciesPerch	382.24	41.90	9.123	1.66e-15 ***
SpeciesPike	718.71	76.05	9.451	2.70e-16 ***
SpeciesRoach	152.05	70.11	2.169	0.032 *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 313.6 on 124 degrees of freedom

Multiple R-squared: 0.7163, Adjusted R-squared: 0.7072

F-statistic: 78.28 on 4 and 124 DF, p-value: < 2.2e-16

Her bir balık türü için katsayılar (coefficients) tahmini ağırlıkları verir. Bu modelde kesme noktası (intercept) sıfırdır, bu nedenle her türün ağırlığı bağımsız olarak raporlanmıştır:

- **SpeciesBream (617.83 gram):** Levrek türü için tahmini ağırlık. Bu katsayı, yüksek bir t-değerine (11.657) ve çok düşük bir p-değerine (< 2e-16) sahip, bu da tahminin oldukça anlamlı olduğunu gösteriyor.
- **SpeciesPerch (382.24 gram):** Sazan türü için tahmini ağırlık. Anlamlı bir tahmin (p-değeri 1.66e-15).
- **SpeciesPike (718.71 gram):** Turna balığı için tahmini ağırlık. Bu da oldukça anlamlı bir tahmindir (p-değeri 2.70e-16).
- **SpeciesRoach (152.05 gram):** Kızılkanat balığı için tahmini ağırlık. Anlamlılık seviyesi daha düşüktür (p-değeri 0.032), ancak %5 anlamlılık düzeyinde istatistiksel olarak anlamlıdır.

Model, türlere göre ağırlık tahmin etmekte oldukça başarılıdır (R-Square: %71.63 varyans açıklanıyor).

Örnek 5:

Regresyon, açıklayıcı değişkenlerin bilinen değerlerinden bir yanıt değişkeninin değerlerini tahmin etmenizi sağlar. Hangi değişkeni yanıt değişkeni olarak kullanacağınız, yanıtlamak istediğiniz soruya bağlıdır, ancak birçok veri setinde tahmin edilmesi ilginç olacak değişkenler için açık bir seçim bulunur. Bu alıştırmalar boyunca, Tayvan emlak veri setini keşfedeceksiniz. Bu veri seti, Yeni Taipei Şehri, Tayvan'ın Sindian Bölgesi'nden toplanan bir gayrimenkul değerlendirme tarihçesine dayanmaktadır. Bu veri setinde, gayrimenkul değerlendirme bir regresyon problemi.

```
library(fst)
taiwan_real_estate <- read.fst(here("data", "taiwan_real_estate.fst"))
str(taiwan_real_estate)
```

```
'data.frame': 414 obs. of 4 variables:
 $ dist_to_mrt_m : num 84.9 306.6 562 562 390.6 ...
 $ n_convenience : num 10 9 5 5 5 3 7 6 1 3 ...
 $ house_age_years: Ord.factor w/ 3 levels "0 to 15"<"15 to 30"<...: 3 2 1 1 1 1 3 2 3 2 ...
 $ price_twd_msq : num 11.5 12.8 14.3 16.6 13 ...
```

Soru 1:

Veri setini görüntüleyerek hangi değişkenin iyi bir yanıt değişkeni olacağını belirleyin.

```
glimpse(taiwan_real_estate)
```

```
Rows: 414
Columns: 4
 $ dist_to_mrt_m    <dbl> 84.87882, 306.59470, 561.98450, 561.98450, 390.56840, ~
 $ n_convenience    <dbl> 10, 9, 5, 5, 5, 3, 7, 6, 1, 3, 1, 9, 5, 4, 4, 2, 6, 1, ~
 $ house_age_years  <ord> 30 to 45, 15 to 30, 0 to 15, 0 to 15, 0 to 15, 0 to 15~
 $ price_twd_msq    <dbl> 11.467474, 12.768533, 14.311649, 16.580938, 13.040847, ~
```


Cevap: Fiyat tahmini, yaygın bir iş görevidir, bu nedenle **house price** (ev fiyatı) iyi bir yanıt değişkenidir. Bu veri setinde, **price_twd_msq** değişkeni yanıt değişkenlerinden biri olabilir.

Soru 2:

Bir istatistiksel model çalıştırmadan önce, veri setini görselleştirmek genellikle iyi bir fikirdir. Burada, ev fiyatı (alan başına fiyat) ile yakınlardaki market (convenience store) sayısı arasındaki ilişkiyi inceleyeceğiz.

```
ggplot(data = taiwan_real_estate, aes(x = n_convenience, y = price_twd_msq)) +
  geom_point(alpha = 0.5) +
  geom_smooth(method = "lm", se = FALSE) +
  scale_x_continuous("Yürüme mesafesindeki market sayısı") +
  scale_y_continuous("Alan başına ev fiyatı (TWD/metrekare)") +
  ggtitle("Tayvan Emlak Fiyatı: Market Sayısının Fiyat Üzerindeki Etkisi") +
  theme_bw()
```

```
`geom_smooth()` using formula = 'y ~ x'
```




Soru 3:

Doğrusal regresyon modelleri her zaman verilere bir doğru çizgisi uydurur. Doğru çizgileri iki özellikle tanımlanır: kesişim noktası (intercept) ve eğim (slope).

Bu alıştırmada, `price_twd_msq` yanıt değişkeni, `n_convenience` ise açıklayıcı değişken olarak kullanılarak bir doğrusal regresyon modeli çalıştıracağız.

```
taiwan_model <- lm(price_twd_msq ~ n_convenience, data = taiwan_real_estate)
plot(price_twd_msq ~ n_convenience, data = taiwan_real_estate)
abline(reg = taiwan_model, col = "red")
```



```
summary(taiwan_model)
```

Call:

```
lm(formula = price_twd_msq ~ n_convenience, data = taiwan_real_estate)
```

Residuals:

Min	1Q	Median	3Q	Max
-10.7132	-2.2213	-0.5409	1.8105	26.5299

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	8.22424	0.28500	28.86	<2e-16 ***
n_convenience	0.79808	0.05653	14.12	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.384 on 412 degrees of freedom

Multiple R-squared: 0.326, Adjusted R-squared: 0.3244

F-statistic: 199.3 on 1 and 412 DF, p-value: < 2.2e-16

Soru 4:

Modelin (Intercept) katsayısı 8.2242 olarak hesaplanmıştır. Bu ne anlama gelir?

Cevap: Ortalama olarak, yakında market bulunmayan bir evin metrekaresi fiyatı **8.2242 TWD**'dir.

Soru 5:

Modelin `n_convenience` katsayısı 0.7981 olarak hesaplanmıştır. Bu ne anlama gelir?

Cevap: Yakındaki market sayısını bir artırdığınızda, ev fiyatında beklenen artış **0.7981 TWD/metrekaresi** olur.

Örnek 6:

Açıklayıcı değişken kategorik olduğunda, verileri görselleştirmek için daha önce kullanılan dağılım grafiği uygun değildir. Bunun yerine, her kategori için bir çubuk grafiği veya histogram oluşturmak iyi bir seçenektir.


Tayvan emlak veri setinde, her evin yaşını gösteren kategorik bir değişken bulunmaktadır. Yaşlar şu şekilde 3 gruba ayrılmıştır: **0-15 yıl**, **15-30 yıl**, ve **30-45 yıl**.

Soru 1:

Tayvan emlak veri setini kullanarak `price_twd_msq` için bir histogram çizin.

```
# ggplot ile histogram ve kategorik gruplandırma
ggplot(data = taiwan_real_estate, aes(x = price_twd_msq)) +
  geom_histogram(bins = 10, fill = "blue", alpha = 0.7) +
  facet_wrap(~house_age_years) +
  labs(
    title = "Ev Fiyatları (TWD/m²) Yaşa Göre Dağılım",
    x = "TWD/m² Fiyatı",
    y = "Frekans"
  ) +
  theme_minimal()
```

Ev Fiyatları (TWD/m²) Yaşa Göre Dağılım



Soru 2:

Ev yaşına (house_age_years) göre verileri gruplandırın.

```
taiwan_real_estate |>
  count(house_age_years)
```

house_age_years	n
0 to 15	190
15 to 30	129
30 to 45	95

Soru 3:

Her grup için price_twd_msq ortalamasını hesaplayın.

```
taiwan_real_estate |>
  group_by(house_age_years) |>
  summarise(mean_price = mean(price_twd_msq, na.rm = TRUE))
```

house_age_years	mean_price
0 to 15	12.637471
15 to 30	9.876743
30 to 45	11.393264

Soru 4:

price_twd_msq'i yanıt değişkeni, house_age_years'i açıklayıcı değişken olarak kullanarak bir doğrusal regresyon modeli çalıştırın. Modeli mdl_price_vs_age olarak atayın.

```
mdl_price_vs_age <- lm(price_twd_msq ~ house_age_years + 0, data = taiwan_real_estate)
summary(mdl_price_vs_age)
```

Call:

```
lm(formula = price_twd_msq ~ house_age_years + 0, data = taiwan_real_estate)
```

Residuals:

Min	1Q	Median	3Q	Max
-10.3379	-2.9119	0.2218	2.5544	22.9147

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
house_age_years0 to 15	12.6375	0.2866	44.10	<2e-16 ***
house_age_years15 to 30	9.8767	0.3478	28.40	<2e-16 ***
house_age_years30 to 45	11.3933	0.4053	28.11	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.95 on 411 degrees of freedom

Multiple R-squared: 0.896, Adjusted R-squared: 0.8953

F-statistic: 1180 on 3 and 411 DF, p-value: < 2.2e-16

Sonuç:

- **0-15 yaş** arası evler ortalama olarak **12.635 TWD/m²** maliyete sahiptir.
- **15-30 yaş** arası evler daha ucuz olup ortalama **9.877 TWD/m²** maliyete sahiptir.
- **30 yıldan daha eski evler**, orta yaşlı evlerden daha pahalıdır. Bu durum dikkatle incelenmelidir.

Açıklama: Daha eski evlerin daha büyük olması, fiyatlarının daha yüksek olmasının bir nedeni olabilir. Bu nedenle, ev büyüklüğü Tayvan emlak piyasasında fiyat tahminlerinde daha iyi bir belirleyici olabilir.

Örnek 7: Çoklu Regresyon

Şimdiye kadar Tayvan emlak veri setinde `n_convenience` ve `house_age_years` değişkenlerini **ayrı ayrı** kullanan iki model kurduk. Ama modülün adı **çoklu** regresyon — iki (veya daha fazla) açıklayıcı değişkeni **aynı anda** modele koyduğumuzda ne değişir?

Model 1: Sürekli + Kategorik (Paralel Eğimler Modeli)

```
mdl_price_vs_both <- lm(price_twd_msq ~ n_convenience + house_age_years + 0,
                        data = taiwan_real_estate)
summary(mdl_price_vs_both)
```

Call:

```
lm(formula = price_twd_msq ~ n_convenience + house_age_years +
    0, data = taiwan_real_estate)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-11.8625	-2.1470	-0.5527	1.6512	25.3474

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
n_convenience	0.79146	0.05448	14.53	<2e-16 ***
house_age_years0 to 15	9.41332	0.32187	29.25	<2e-16 ***
house_age_years15 to 30	7.08517	0.34201	20.72	<2e-16 ***
house_age_years30 to 45	7.51096	0.42440	17.70	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.213 on 410 degrees of freedom

Multiple R-squared: 0.9314, Adjusted R-squared: 0.9307

F-statistic: 1391 on 4 and 410 DF, p-value: < 2.2e-16

Bu, **paralel eğimler modeli** olarak adlandırılır: her yaş grubu için ayrı bir kesme noktası (intercept) tahmin edilir, ama `n_convenience`'ın etkisi (eğim) üç grup için de **aynı** kabul

edilir — yani market sayısındaki bir birimlik artışın fiyata etkisi, evin yaşından bağımsız olarak sabittir.

Yorum:

- Yaş grubu sabit tutulduğunda (yani aynı yaş grubundaki evler karşılaştırıldığında), her ek yakın market fiyatı ortalama **0.79 TWD/m²** artırır — Örnek 5'teki 0.80 değerine çok yakın, çünkü iki değişken arasında güçlü bir korelasyon yok.
- 0-15 yaş grubunun kesme noktası (9.41), Örnek 6'daki tek-değişkenli modelin (12.64) **altındadır**. Bu tesadüf değildir: tek-değişkenli modelde bu grubun daha yüksek görünmesinin bir kısmı, o gruptaki evlerin ortalamada daha fazla yakın markete sahip olmasından kaynaklanıyordu; `n_convenience`'i modele eklediğimizde bu pay ondan “alınmış” oldu.
- Model, fiyat varyansının **%39.5**'ini açıklıyor (tek başına `n_convenience` ile %32.6, tek başına `house_age_years` ile bundan da az) — iki değişkeni birlikte kullanmak, ayrı ayrı kullanmaktan daha fazla bilgi taşır.

💡 Paralel eğimler mi, etkileşim mi?

+ operatörü modele “eğim her grupta aynı” varsayımını dayatır. Bu varsayımın gerçekten geçerli olup olmadığını sınamak için `n_convenience * house_age_years` (etkileşim terimi) ile bir model kurup iki modeli karşılaştırmak mümkündür — ama bu, 13. modülün konusu olan **model karşılaştırma ve seçimi**'nin kapsamına girer.

Model 2: İki Sürekli Değişken ve Çoklu Doğrusallık

Şimdi `house_age_years`'ı bir kenara bırakıp, iki *sürekli* açıklayıcı değişkeni birlikte kullanalım: `n_convenience` ve `dist_to_mrt_m` (en yakın metro istasyonuna mesafe, metre).

```
mdl_price_vs_conv_dist <- lm(price_twd_msq ~ n_convenience + dist_to_mrt_m,
                             data = taiwan_real_estate)
summary(mdl_price_vs_conv_dist)
```

Call:

```
lm(formula = price_twd_msq ~ n_convenience + dist_to_mrt_m, data = taiwan_real_estate)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-11.0484	-1.7736	-0.4108	1.4468	23.7786

Coefficients:

```

              Estimate Std. Error t value Pr(>|t|)
(Intercept)  11.837490   0.393194  30.106 < 2e-16 ***
n_convenience 0.362360   0.061291   5.912 7.11e-09 ***
dist_to_mrt_m -0.001688   0.000143 -11.799 < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.928 on 411 degrees of freedom
Multiple R-squared:  0.4966,    Adjusted R-squared:  0.4941
F-statistic: 202.7 on 2 and 411 DF,  p-value: < 2.2e-16

```

Yorum:

- Model tek başına $R^2 = 0.497$ elde ediyor — `dist_to_mrt_m` tek başına (0.454) veya `n_convenience` tek başına (0.326) kullanılan modellerden daha güçlü.
- `n_convenience` katsayısı (0.36), Model 1'deki (0.79) veya Örnek 5'teki (0.80) değerden **belirgin biçimde küçük**. Neden?

```
cor(taiwan_real_estate$n_convenience, taiwan_real_estate$dist_to_mrt_m)
```

```
[1] -0.6025191
```

Bu iki değişken arasında orta-güçlü bir korelasyon var ($r \approx -0.60$): metroya yakın evlerin çevresinde daha çok market bulunma eğilimi var. Tek başına kullanıldığında `n_convenience`, kısmen `dist_to_mrt_m`'nin taşıdığı bilgiyi de “üstleniyordu”; ikisi birlikte modele girince her biri yalnızca **kendi özgün katkısını** temsil ediyor.

! Çoklu doğrusallık (multicollinearity) ve VIF

Açıklayıcı değişkenler birbiriyle ne kadar güçlü ilişkiliyse, katsayı tahminleri o kadar **kararsız** (yüksek standart hatalı) hâle gelir — çünkü model, gözlenen fiyat değişiminin ne kadarının hangi değişkenden geldiğini ayırt etmekte zorlanır. Bunu sayısalılaştırmak için **Varyans Şişirme Faktörü (VIF)** kullanılır:

```
library(car)
```

```
Loading required package: carData
```

```
Attaching package: 'car'
```

```
The following object is masked from 'package:dplyr':
```

```
recode
```

```
vif mdl_price_vs_conv_dist)
```

```
n_convenience dist_to_mrt_m  
1.569931      1.569931
```

Genel kural: $VIF > 5$ dikkat çekici, $VIF > 10$ ciddi bir çoklu doğrusallık işaretidir. Buradaki ≈ 1.57 değeri, -0.60 'lık korelasyona rağmen **düşüktür** — yani bu iki değişkeni birlikte kullanmak güvenlidir. Bu, önemli bir dersi gösterir: **iki değişken arasında korelasyon olması, onları birlikte kullanmayı otomatik olarak sorunlu yapmaz**; VIF, korelasyonun katsayı kararlılığını ne kadar etkilediğini doğrudan ölçer.

1. Negatif Kesme Noktası (Intercept):

- Kesme noktası (β_0) negatif olduğunda, bu değer fiziksel anlamı olup olmadığını değerlendirmek önemlidir. Örneğin, negatif bir fiyat fiziksel olarak anlamlı değildir ve model bu durumda yeniden değerlendirilmelidir.

2. Kategorik Bağımsız Değişkenler:

- Kategorik değişkenler regresyon modeline doğrudan dahil edilemez. Bunun yerine, kategorik değişkenler **dummy değişkenlere** dönüştürülmelidir. Örneğin, “evet/hayır” gibi iki kategorili bir değişken bir 0 ve 1 değeriyle kodlanabilir.

3. Lineerlik Varsayımı:

- Doğrusal regresyon, bağımlı ve bağımsız değişkenler arasındaki ilişkinin doğrusal olduğunu varsayar. Bu varsayımı doğrulamak için grafiksel analiz (dağılım grafikleri) yapılmalıdır.

4. Ölçüm Birimleri:

- Bağımsız değişkenlerin birimleri modelde büyük farklar yaratabilir. Bu nedenle, bazı durumlarda değişkenleri standardize etmek faydalıdır. (**z-skorları hatırlayın!**)

5. Artıklar (Residuals):

- Artıkların normal dağılım ve sabit varyans varsayımlarını sağladığından emin olunmalıdır. `broom::glance()` ve `performance::check_model()` ile bu varsayımlar 11. modülde gösterildiği gibi görsel olarak da denetlenebilir.

6. Çoklu Doğrusallık (Multicollinearity):

- Birden fazla açıklayıcı değişken kullanıldığında, bu değişkenlerin birbiriyle çok yüksek korelasyonlu olması katsayı tahminlerini kararsızlaştırabilir. `car::vif()` fonksiyonu ile her değişkenin Varyans Şişirme Faktörü (VIF) hesaplanır; genel kabul gören eşik $VIF > 5$ (bazı kaynaklarda 10) değeridir — bkz. Örnek 7.