

Modül 13: Lojistik Regresyon

Prof. Dr. Hakan Mehmetcik

2026-09-13

Lojistik Regresyona Giriş

Lojistik regresyon, bir bağımlı değişkenin **ikili (binary)** veya **çoklu (multinomial)** kategorilerden oluştuğu durumlarda, bu bağımlı değişken ile bir veya birden fazla bağımsız değişken arasındaki ilişkiyi modellemek için kullanılan bir istatistiksel yöntemdir.

Özellikleri:

1. Bağımlı Değişken:

- İkili lojistik regresyon: Bağımlı değişken iki kategorilidir (ör., 0 ve 1).
- Çoklu lojistik regresyon: Bağımlı değişken birden fazla kategorilidir (ör., A, B, C).

2. Bağımsız Değişkenler:

- Sürekli veya kategorik olabilir.
- Örneğin, yaş, cinsiyet, eğitim düzeyi.

3. Amaç:

- Bağımlı değişkenin belirli bir kategoriye ait olma olasılığını tahmin etmek (ör., “Evet” oyu verme olasılığı).
- Bağımsız değişkenlerin bağımlı değişken üzerindeki etkisini ölçmek.

1. Logit Fonksiyonu:

- Lojistik regresyon, bağımlı değişkenin **log-odds**'larını bağımsız değişkenlerle ilişkilendirir:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

- p : Bağımlı değişkenin 1 olma olasılığı.
- $1 - p$: Bağımlı değişkenin 0 olma olasılığı.
- β_0 : Sabit terim (intercept).
- β_i : Bağımsız değişkenlerin katsayıları.

2. Odds ve Odds Oranı:

- **Odds:** Bir olayın gerçekleşme olasılığı ile gerçekleşmeme olasılığı arasındaki oran:

$$\text{Odds} = \frac{p}{1 - p}$$

- **Odds Oranı (Odds Ratio):** Bir bağımsız değişkendeki bir birimlik artışın bağımlı değişken üzerindeki etkisini gösterir:

$$\text{Odds Ratio} = e^{\beta}$$

R'da Lojistik Regresyon Modeli

```
logit_model <- glm(y ~ x1 + x2 + x3, family = binomial, data = my_data)
summary(logit_model)
```

Örnek 1:

Bir kişinin kredi alıp alamaması (`kredi_onay` = 0 veya 1) ile geliri (`gelir`) ve kredi puanı (`kredi_puanı`) arasındaki ilişkiyi incelemek istiyoruz.

```
# Basit bir veri seti
data <- data.frame(
  kredi_onay = c(0, 1, 0, 1, 0, 1, 1, 0, 1, 0), # 0 = reddedildi, 1 = onaylandı
  gelir = c(3000, 5000, 2500, 8000, 2000, 7000, 6000, 2200, 9000, 1500), # Gelir düzeyi
  kredi_puanı = c(600, 750, 580, 800, 550, 720, 700, 590, 820, 510) # Kredi puanı
)

# Veri setini görüntüleme
print(data)
```

	kredi_onay	gelir	kredi_puani
1	0	3000	600
2	1	5000	750
3	0	2500	580
4	1	8000	800
5	0	2000	550
6	1	7000	720
7	1	6000	700
8	0	2200	590
9	1	9000	820
10	0	1500	510

Lojistik Regresyon Modeli

Bağımlı değişken: **kredi_onay**

Bağımsız değişkenler: **gelir** ve **kredi_puani**

```
# Lojistik regresyon modeli
logit_model <- glm(kredi_onay ~ gelir + kredi_puani, family = binomial, data = data)
```

Warning: glm.fit: fitted probabilities numerically 0 or 1 occurred

```
# Modelin özetini görüntüleme
summary(logit_model)
```

Call:

```
glm(formula = kredi_onay ~ gelir + kredi_puani, family = binomial,
    data = data)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.696e+02	8.265e+05	0	1
gelir	8.688e-03	6.538e+01	0	1
kredi_puani	2.009e-01	1.637e+03	0	1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 1.3863e+01 on 9 degrees of freedom
 Residual deviance: 4.2672e-10 on 7 degrees of freedom
 AIC: 6

Number of Fisher Scoring iterations: 24

Katsayılar, bağımsız değişkenlerin bağımlı değişken üzerindeki etkilerini temsil eder. Ancak render sırasında R şu uyarıyı verir:

Warning message:

glm.fit: fitted probabilities numerically 0 or 1 occurred

Bu uyarı, **tam ayrışma (perfect/complete separation)** adı verilen bir durumun işareti-dir: bu küçük (10 gözlemlik) veri setinde, **gelir** ve **kredi_puani** değişkenleri **kredi_onay**'ı **kusursuz biçimde** ayırıyor — belirli bir eşğin üzerindeki her başvuru onaylanmış, altındaki her başvuru reddedilmiş. Model bu kusursuz ayrımı “öğrenmeye” çalışırken katsayıları sonsuza yaklaştırır (**gelir/kredi_puani** katsayıları makul görünse de, **standart hataları** milyonlarca birim büyüklüğündedir):

- **Intercept (-169.6):** Çok yüksek bir negatif değer; standart hatası da (826.500) katsayının kendisinden çok daha büyük — bu, tahminin **güvenilmez** olduğunun doğrudan göstergesidir.
- **gelir (0.0087) ve kredi_puani (0.2009):** Sayısal değerleri makul görünse de, standart hataları (sırasıyla 65 ve 1637) katsayıların kendisinden binlerce kat büyüktür.

Pr(>|z|) sütunundaki değerler:

- Tüm değişkenler için **1**, yani Wald testi bu koşullarda **anlamsız** hale gelir — bu, değişkenlerin gerçekten etkisiz olduğu anlamına gelmez, tam tersine model o kadar “mükemmel” uyuyor ki test istatistiği çöküyor.
- **Residual deviance** neredeyse **sıfırdır** (model verideki her noktayı kusursuz tahmin ediyor) — ama bu bir başarı değil, tam ayrışmanın bir belirtisidir.

Bu model, veri setinin küçük olması ve bağımsız değişkenlerle bağımlı değişkenin tam ayrışması nedeniyle güvenilir sonuçlar üretememiştir. Şimdi gerçek hayattan bir örnekle lojistik regresyonu inceleyelim.

Örnek 2:

Bu alıştırmada “[The Scottish Social Attitudes \(SSA\) survey](#)” ismiyle bilinen ve 1999 yılından bu yana İskoçya’daki insanların sosyal, politik ve ahlaki tutumlarındaki değişiklikleri takip eden bir anket serisinin 2019 yılı anket sonuçlarını kullanacağız.

Bu anket verisi içinde yer alan değişkenler aşağıdaki şekilde:

- **pserial:** Katılımcıya özgü bir tanımlayıcı.
- **rsex:** Cinsiyet (ör., “Male” veya “Female”).
- **rage:** Katılımcının yaş kategorisi (ör., 31, 41 gibi).
- **incsour:** Gelir kaynağı (ör., “Wages/private income source”, “State Benefits”).
- **leftrigh:** Sol-sağ siyasi eğilim skalası (ör., 1.2, 2.4 gibi sürekli değerler).
- **libauth:** Liberal-otoriter eğilim skalası (ör., 2.833, 4.0 gibi sürekli değerler).
- **employment:** Katılımcının istihdam durumu (ör., “3. Employed”, “5. Permanently Sick/Disabled”).
- **employmentdum:** İstihdam durumunun ikili kategorik versiyonu (ör., “1. Employed”, “NaN”).
- **PtyAllgS_NoNa:** Parti bağlılığına ilişkin bir ölçüm (ör., 4.0, 5.0 gibi sürekli değerler).
- **GovTrust_NoNa:** Hükümete güven düzeyine ilişkin bir ölçüm (ör., 3.0, 4.0 gibi sürekli değerler).
- **TaxSpend_NoNa:** Vergi ve harcama politikalarına ilişkin görüşler (ör., 4.0, 5.0 gibi sürekli değerler).
- **ECPolicy_NoNa:** Ekonomi politikalarına ilişkin görüşler (ör., 3.0, 5.0 gibi sürekli değerler).
- **LetIn_NoNa:** Göçmen kabulüne ilişkin görüşler (ör., 4.0, 5.0 gibi sürekli değerler).
- **EvCameron_NoNa:** David Cameron hakkındaki değerlendirmeler (ör., 3.0, 4.0 gibi sürekli değerler).
- **EvSalmond_NoNa:** Alex Salmond hakkındaki değerlendirmeler (ör., 2.0, 4.0 gibi sürekli değerler).
- **Knowind_NoNa:** Bağımsızlık referandumu hakkında bilgi düzeyi (ör., 4.0, 5.0 gibi sürekli değerler).
- **liklyvt_NoNa:** Oy kullanma olasılığı (ör., 10.0).
- **Refvote_NoNa:** Referandumda hangi yönde oy kullanıldığı (ör., 1.0, 3.0 gibi kategoriler).
- **SEBenGB_NoNa:** İskoçya’nın Birleşik Krallık’a ekonomik faydalarına dair görüşler (ör., 1.0, 2.0 gibi sürekli değerler).
- **RefvoteDum:** Referandum oyunun ikili kategorisi (ör., “1. Vote Yes”, “0. Vote No”).
- **UKSpenGB_NoNa:** Birleşik Krallık harcamalarına ilişkin görüşler (ör., 4.0, 5.0 gibi sürekli değerler).

- **ScotID_NoNa:** İskoç kimliğine dair görüşler (ör., 6.0, 7.0 gibi sürekli değerler).
- **HEdQual2_NoNa:** Katılımcının eğitim düzeyi (ör., 4.0, 8.0 gibi kategoriler).
- **Party_Labels:** Katılımcının siyasi parti tercihi (ör., “2. Labour”).
- **PartyFW_NoNa:** Siyasi partilere yönelik görüşlerin bir ölçütü (ör., 2.0, 3.0 gibi sürekli değerler).
- **Dole_NoNa:** İşsizlik yardımlarına dair görüşler (ör., 1.0, 2.0 gibi sürekli değerler)

1. Veri Setini Okuma

```
library(haven)
library(here)
```

here() starts at /Users/kobain/Dersler/IST2083

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2
```

```
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
# Veri setini okuma
scottish <- read_dta((here("data", "scottish.dta")))

# İlk birkaç satıra göz atalım
head(scottish)
```

	pserial	rsex	age	incsour	leftrigh	libauth	employment	employmentdum	PtyAllgS_NoNa	GovTrust_NoNa	TaxSpend_NoNa	ECPolicy_NoNa	LetIn_NoNa	EvCameron_NoNa	EvSalmond_NoNa	Knowind_NoNa	liklyvt_NoNa	Refvote_NoNa	SEBenGB_NoNa	RefvoteDum	UKSpenGB_NoNa	ScotID_NoNa	HedQual2_NoNa	Party_Labels
151343	1	2	1.2	2.833333	3	5	4	2	5	5	2	5	4	10	1	1	1	5	7	4	2	2	1	
151856	1	2	1.8	3.500000	0	5	3	3	NA	4	2	4	4	10	3	1	NA	4	6	8	2	2	NA	
151537	3	2	2.0	4.000000	0	4	4	2	4	5	5	3	2	10	2	1	0	4	4	8	2	2	2	
151369	1	1	1.8	4.666667	NA	5	4	3	1	5	0	5	3	10	1	1	1	5	6	5	2	2	1	
152010	1	1	2.4	3.833333	NA	NA	4	2	2	1	4	5	4	10	3	1	NA	5	7	NA	NA	NA	1	
151793	0	2	1.8	3.833333	NA	NA	NA	3	2	5	5	6	4	7	3	1	NA	NA	7	8	NA	NA	NA	

2. Veri Setinin Genel Yapısını Anlama

```
# Veri setinin yapısını inceleme
glimpse(scottish)
```

```
Rows: 1,501
Columns: 26
$ pserial      <dbl> 151343, 151856, 151537, 151369, 152010, 151793, 151589,~
$ rsex         <dbl+lbl> 1, 2, 1, 1, 2, 2, 2, 1, 1, 2, 2, 2, 2, 1, 2, 2, 2, ~
$ rage        <dbl+lbl> 31, 41, 53, 39, 43, 60, 86, 49, 43, 53, 53, 49, 42,~
$ incsour     <dbl+lbl> 2, 2, 2, 1, 1, 2, 1, 2, 1, 2, 2, 2, 2, ~
$ leftrigh    <dbl+lbl> 1.2, 1.8, 2.0, 1.8, 2.4, 1.8, 1.0, 2.4, 2.~
$ libauth     <dbl+lbl> 2.833333, 3.500000, 4.000000, 4.666667, 3.8333~
$ employment <dbl+lbl> 3, 3, 3, 5, 7, 3, 6, 3, 4, 3, 3, 3, 3, 3, 4, 3, 3, ~
$ employmentdum <dbl+lbl> 1, 1, 1, NA, NA, 1, NA, 1, 0, 1, 1, 1, 1, ~
$ PtyAllgS_NoNa <dbl> 5, 5, 4, 5, NA, NA, 4, 4, 12, 12, NA, 10, 11, 11, NA, 1~
$ GovTrust_NoNa <dbl> 4, 3, 4, 4, 4, NA, 4, 3, 4, 4, 4, 4, 4, 3, 2, 1, 3, 3, ~
$ TaxSpend_NoNa <dbl> 2, 3, 2, 3, 2, 3, 3, 3, NA, 3, NA, 3, 3, 3, 3, 2, 2, 1,~
$ ECPolicy_NoNa <dbl> 5, NA, 4, 1, 2, 2, 2, 2, 2, 2, NA, 1, 1, 1, 5, 3, 1, NA~
$ LetIn_NoNa  <dbl> 5, 4, 5, 5, 1, 5, 5, 3, 5, 5, 5, 5, 5, 4, 4, 3, 5, 5, 5~
$ EvCameron_NoNa <dbl> 2, 2, 5, 0, 4, 5, 0, 5, 0, 0, 0, 0, 2, 3, 0, 9, 1, 5, 7~
$ EvSalmond_NoNa <dbl> 5, 4, 3, 5, 5, 6, 0, 1, 6, 0, 0, 7, 5, 7, NA, 10, 1, 7,~
$ Knowind_NoNa <dbl> 4, 4, 2, 3, 4, 4, 5, 3, 3, 4, 5, 3, 3, 3, 4, 4, 3, 4, 5~
$ liklyvt_NoNa <dbl> 10, 10, 10, 10, 10, 7, 10, 10, 10, 0, 1, 10, 10, 10, 5,~
$ Refvote_NoNa <dbl> 1, 3, 2, 1, 3, 3, 2, 2, 3, 2, 3, 1, 1, NA, 2, 3, 2, 3, ~
$ SEBenGB_NoNa <dbl> 1, 1, 1, 1, 1, 1, 1, 2, 1, NA, 1, 1, 1, 2, 3, NA, 1, 1,~
$ RefvoteDum  <dbl+lbl> 1, NA, 0, 1, NA, NA, 0, 0, NA, 0, NA, 1, 1,~
$ UKSpenGB_NoNa <dbl> 5, 4, 4, 5, 5, NA, 5, 3, 5, 5, 5, 4, 4, 5, NA, 3, NA, 4~
$ ScotID_NoNa <dbl> 7, 6, 4, 6, 7, 7, 7, 7, 7, 7, 7, 7, 4, 7, 1, 4, 7, 7, 7~
$ HedQual2_NoNa <dbl> 4, 8, 8, 5, NA, 8, 8, 4, 8, 8, 8, 3, 5, 8, 8, 8, 4, 5, ~
$ Party_Labels <dbl+lbl> 2, 2, 2, 2, NA, NA, 2, 2, 4, 4, NA, 4, 4,~
```

```
$ PartyFW_NoNa    <dbl> 2, 2, 2, 2, NA, NA, 2, 2, 4, 4, 10, 4, 4, 4, NA, 4, NA,~
$ Dole_NoNa      <dbl> 1, NA, 2, 1, 1, NA, 2, 2, 1, NA, 3, 1, NA, 3, NA, 2, NA~
```

```
# Sütun isimlerini ve sayısını kontrol etme
colnames(scottish)
```

```
[1] "pserial"      "rsex"         "rage"         "incsour"
[5] "leftrigh"     "libauth"      "employment"   "employmentdum"
[9] "PtyAllgS_NoNa" "GovTrust_NoNa" "TaxSpend_NoNa" "ECPolicy_NoNa"
[13] "LetIn_NoNa"   "EvCameron_NoNa" "EvSalmond_NoNa" "Knowind_NoNa"
[17] "liklyvt_NoNa" "Refvote_NoNa"  "SEBenGB_NoNa"  "RefvoteDum"
[21] "UKSpenGB_NoNa" "ScotID_NoNa"   "HEdQual2_NoNa" "Party_Labels"
[25] "PartyFW_NoNa" "Dole_NoNa"
```

Temel veri manüplasyonu:

```
scottish <- scottish %>%
  mutate(pid      = as_factor(Party_Labels, levels = "labels"),
         trust     = as.numeric(fct_rev(as_factor(GovTrust_NoNa))),
         age       = na_if(na_if(rage, 98), 99),
         edu1      = na_if(HEdQual2_NoNa, 7),
         sex_erkek = if_else(as_factor(rsex) == "Male", 1, 0)) |>
  mutate(pid1 = recode_factor(pid,
    "1. Conservative" = "1. Conservative",
    "2. Labour"       = "2. Labour",
    "4. SNP"          = "3. SNP",
    .default = NA_character_))
```

i Bu satırlarda neler oluyor?

- **trust:** GovTrust_NoNa orijinalde 1-4 arası bir ölçektir. `fct_rev()` bu ölçeğin yönünü tersine çevirir, `as.numeric()` ise geri sayısal bir değere dönüştürür — sonuç, orijinaliyle aynı bilgiyi taşıyan ama ters yönde kodlanmış bir değişkendir.
- **age:** `rage` değişkeni Stata'dan `haven::read_dta()` ile okunduğunda **sayısal** kalır (bir faktöre dönüştürülmez), ama anket kodlamasında **98 = “Bilmiyorum”** ve **99 = “Cevap yok”** özel kodları da düz sayı olarak saklanır. Bunlar `na_if()` ile temizlenmezse, birkaç kişi “98 yaşında” veya “99 yaşında” gibi görünür ve ortalama/regresyon sonuçlarını hafifçe çarpıtır (bu veri setinde yalnızca 3 kişiyi etkiliyor, ama ilke önemlidir: **anket verilerinde özel kodları her zaman kontrol edin**, bkz. 2. modül).
- **edu1:** HEdQual2_NoNa'nın 7. kategorisi, geri kalan kategorilerle tutarlı bir sıralama

oluşturmuyor; `na_if()` ile analiz dışı bırakıldı.

- **sex_erkek:** `rsex` de `age` gibi ham sayısal bir değişkendir (1 = Erkek, 2 = Kadın). Bunu **doğrudan** bir regresyon modeline sokmak, R'ın bunu otomatik olarak bir kategorik (dummy) değişken gibi ele alacağı anlamına **gelmez** — model onu 1'den 2'ye **sürekli bir sayı** olarak okur. Sonuç sayısal olarak “çalışır” ve hata vermez, ama katsayının yönünü yanlış yorumlamak çok kolaydır. Bu yüzden burada açık bir 0/1 dummy (`sex_erkek`) oluşturuyoruz — hem doğru hem de okunması güvenli.

3. Eksik Verilerin Kontrolü

```
# Eksik veri yüzdesini hesaplama
scottish %>%
  summarise(across(everything(), ~ mean(is.na(.)) * 100)) %>%
  pivot_longer(cols = everything(), names_to = "Column", values_to = "Missing_Percentage") %>%
  arrange(desc(Missing_Percentage))
```

Column	Missing_Percentage
employmentdum	42.5049967
pid1	33.5776149
RefvoteDum	31.1125916
PtyAllgS_NoNa	28.9140573
Party_Labels	23.6508994
pid	23.6508994
PartyFW_NoNa	10.9926716
ECPolicy_NoNa	8.7941372
Dole_NoNa	8.1945370
UKSpenGB_NoNa	7.5283145
SEBenGB_NoNa	6.5289807
EvSalmond_NoNa	4.3304464
TaxSpend_NoNa	3.9973351
EvCameron_NoNa	2.7315123
edu1	2.2651566
LetIn_NoNa	2.0652898
GovTrust_NoNa	1.9986676
trust	1.9986676
employment	0.9327115
liklyvt_NoNa	0.5329780
Refvote_NoNa	0.5329780
HEdQual2_NoNa	0.5329780

Column	Missing_Percentage
ScotID_NoNa	0.2664890
age	0.1998668
Knowind_NoNa	0.1332445
pserial	0.0000000
rsex	0.0000000
rage	0.0000000
incsour	0.0000000
leftrigh	0.0000000
libauth	0.0000000
sex_erkek	0.0000000

Eksik Verilerin İşlenmesi

Eksik veriler için temel stratejiler:

- Eksik verileri silme:
- Eksik verileri doldurma (ör: sütun medyanı/ortalaması ile)

Biz ikinci yöntemi kullanalım:

```
scottish_clean <- scottish %>%
  mutate(across(where(is.numeric), ~ ifelse(is.na(.), median(., na.rm = TRUE), .)))
```

Hala bazı verilerde “Not applicable” ve “Missing Values” ibareleri var. Bunların da temizlenmesi ya da ilgili değişkenin kullanımında farklı tekniklerin kullanılması gerekiyor.

```
glimpse(scottish_clean)
```

Rows: 1,501

Columns: 32

```
$ pserial      <dbl> 151343, 151856, 151537, 151369, 152010, 151793, 151589,~
$ rsex         <dbl> 1, 2, 1, 1, 2, 2, 2, 1, 1, 2, 2, 2, 2, 1, 2, 2, 2, 1, 1~
$ rage         <dbl> 31, 41, 53, 39, 43, 60, 86, 49, 43, 53, 53, 49, 42, 50,~
$ incsour      <dbl> 2, 2, 2, 1, 1, 2, 1, 2, 1, 2, 2, 2, 2, 2, 1, 2, 1, 1, 1~
$ leftrigh     <dbl> 1.2, 1.8, 2.0, 1.8, 2.4, 1.8, 1.0, 2.4, 2.0, 2.4, 1.0, ~
$ libauth      <dbl> 2.833333, 3.500000, 4.000000, 4.666667, 3.833333, 3.833~
$ employment   <dbl> 3, 3, 3, 5, 7, 3, 6, 3, 4, 3, 3, 3, 3, 3, 4, 3, 3, 6, 4~
$ employmentdum <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1, 0, 1, 1, 1, 0~
$ PtyAllgS_NoNa <dbl> 5, 5, 4, 5, 6, 6, 4, 4, 12, 12, 6, 10, 11, 11, 6, 12, 6~
$ GovTrust_NoNa <dbl> 4, 3, 4, 4, 4, 3, 4, 3, 4, 4, 4, 4, 4, 4, 3, 2, 1, 3, 3, 4~
```

```

$ TaxSpend_NoNa <dbl> 2, 3, 2, 3, 2, 3, 3, 3, 2, 3, 2, 3, 3, 3, 3, 2, 2, 1, 3~
$ ECPolicy_NoNa <dbl> 5, 2, 4, 1, 2, 2, 2, 2, 2, 2, 2, 1, 1, 1, 5, 3, 1, 2, 2~
$ LetIn_NoNa <dbl> 5, 4, 5, 5, 1, 5, 5, 3, 5, 5, 5, 5, 5, 4, 4, 3, 5, 5, 5~
$ EvCameron_NoNa <dbl> 2, 2, 5, 0, 4, 5, 0, 5, 0, 0, 0, 0, 2, 3, 0, 9, 1, 5, 7~
$ EvSalmond_NoNa <dbl> 5, 4, 3, 5, 5, 6, 0, 1, 6, 0, 0, 7, 5, 7, 5, 10, 1, 7, ~
$ Knowind_NoNa <dbl> 4, 4, 2, 3, 4, 4, 5, 3, 3, 4, 5, 3, 3, 3, 4, 4, 3, 4, 5~
$ liklyvt_NoNa <dbl> 10, 10, 10, 10, 10, 7, 10, 10, 10, 0, 1, 10, 10, 10, 5, ~
$ Refvote_NoNa <dbl> 1, 3, 2, 1, 3, 3, 2, 2, 3, 2, 3, 1, 1, 2, 2, 3, 2, 3, 3~
$ SEBenGB_NoNa <dbl> 1, 1, 1, 1, 1, 1, 1, 2, 1, 2, 1, 1, 1, 2, 3, 2, 1, 1, 3~
$ RefvoteDum <dbl> 1, 0, 0, 1, 0, 0, 0, 0, 0, 0, 0, 1, 1, 0, 0, 0, 0, 0, 0~
$ UKSpenGB_NoNa <dbl> 5, 4, 4, 5, 5, 3, 5, 3, 5, 5, 5, 4, 4, 5, 3, 3, 3, 4, 4~
$ ScotID_NoNa <dbl> 7, 6, 4, 6, 7, 7, 7, 7, 7, 7, 7, 7, 4, 7, 1, 4, 7, 7, 7~
$ HEdQual2_NoNa <dbl> 4, 8, 8, 5, 4, 8, 8, 4, 8, 8, 8, 3, 5, 8, 8, 8, 4, 5, 8~
$ Party_Labels <dbl> 2, 2, 2, 2, 2, 2, 2, 2, 4, 4, 2, 4, 4, 4, 2, 4, 2, 4, 2~
$ PartyFW_NoNa <dbl> 2, 2, 2, 2, 3, 3, 2, 2, 4, 4, 10, 4, 4, 4, 3, 4, 3, 4, ~
$ Dole_NoNa <dbl> 1, 2, 2, 1, 1, 2, 2, 2, 1, 2, 3, 1, 2, 3, 2, 2, 2, 3, 1~
$ pid <fct> 2. Labour, 2. Labour, 2. Labour, 2. Labour, NA, NA, 2. ~
$ trust <dbl> 1, 2, 1, 1, 1, 2, 1, 2, 1, 1, 1, 1, 1, 2, 3, 4, 2, 2, 1~
$ age <dbl> 31, 41, 53, 39, 43, 60, 86, 49, 43, 53, 53, 49, 42, 50, ~
$ edu1 <dbl> 4, 8, 8, 5, 4, 8, 8, 4, 8, 8, 8, 3, 5, 8, 8, 8, 4, 5, 8~
$ sex_erkek <dbl> 1, 0, 1, 1, 0, 0, 0, 1, 1, 0, 0, 0, 0, 1, 0, 0, 0, 1, 1~
$ pid1 <fct> 2. Labour, 2. Labour, 2. Labour, 2. Labour, NA, NA, 2. ~

```

4. Temel Özet İstatistikler

Analiz yapmadan önce, hangi sütunların kategorik veya sürekli olduğunu anlamak önemlidir. Bu bilgi dönüşüm veya filtreleme işlemlerinde yardımcı olur.

```

# Sayısal değişkenleri seçme
numeric_vars <- scottish_clean %>%
  select(where(is.numeric))

# Sayısal değişkenlerin isimleri
colnames(numeric_vars)

```

```

[1] "pserial"      "rsex"         "rage"         "incsour"
[5] "leftrigh"    "libauth"      "employment"    "employmentdum"
[9] "PtyAllgS_NoNa" "GovTrust_NoNa" "TaxSpend_NoNa" "ECPolicy_NoNa"
[13] "LetIn_NoNa"   "EvCameron_NoNa" "EvSalmond_NoNa" "Knowind_NoNa"
[17] "liklyvt_NoNa" "Refvote_NoNa"  "SEBenGB_NoNa"  "RefvoteDum"
[21] "UKSpenGB_NoNa" "ScotID_NoNa"   "HEdQual2_NoNa" "Party_Labels"

```

```
[25] "PartyFW_NoNa" "Dole_NoNa"      "trust"          "age"
[29] "edu1"          "sex_erkek"
```

```
# Kategorik değişkenleri seçme
categorical_vars <- scottish_clean %>%
  select(where(is.factor))

# Kategorik değişkenlerin isimleri
colnames(categorical_vars)
```

```
[1] "pid" "pid1"
```

5. Sayısal Değişkenler için Dağılım ve Özet İstatistikler:

```
# Temel istatistikler
scottish_clean %>%
  summarise(
    mean_age = mean(rage, na.rm = TRUE),
    mean_trust = mean(trust, na.rm = TRUE),
    mean_edu = mean(edu1, na.rm = TRUE),
    sd_age = sd(age, na.rm = TRUE),
    sd_trust = sd(trust, na.rm = TRUE),
    sd_edu = sd(edu1, na.rm = TRUE)
  )
```


mean_age	mean_trust	mean_edu	sd_age	sd_trust	sd_edu
52.27715	1.763491	4.469021	17.69896	0.7362243	2.195117

```
library(ggplot2)


# Yaş histogramı ve yoğunluk grafiği
ggplot(scottish_clean, aes(x = age)) +
  geom_histogram(binwidth = 5, fill = "blue", alpha = 0.7) +
  geom_density(aes(y = ..count..), color = "red", size = 1) +
  labs(title = "Yaş Dağılımı", x = "Yaş", y = "Frekans")
```

Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
i Please use `linewidth` instead.

Warning: The dot-dot notation (`..count..`) was deprecated in ggplot2 3.4.0.
i Please use `after_stat(count)` instead.




```
# Eğitim histogramı ve yoğunluk grafiği
ggplot(scottish_clean, aes(x = edu1)) +
  geom_histogram(binwidth = 1, fill = "purple", alpha = 0.7) +
  geom_density(aes(y = ..count..), color = "red", size = 1) +
  labs(title = "Eğitim Düzeyi Dağılımı", x = "Eğitim Düzeyi", y = "Frekans")
```




```
library(ggplot2)

# Güven değişkeni bar grafiği
ggplot(scottish_clean, aes(x = trust)) +
  geom_bar(fill = "blue", alpha = 0.7) +
  labs(title = "Güven Dağılımı", x = "Güven", y = "Frekans")
```



```
# Eğitim değişkeni bar grafiği  
ggplot(scottish_clean, aes(x = edu1)) +  
  geom_bar(fill = "purple", alpha = 0.7) +  
  labs(title = "Eğitim Düzeyi Dağılımı", x = "Eğitim Düzeyi", y = "Frekans")
```



```
# Spearman korelasyonu
scottish_clean %>%
  select(trust, edu1, age) %>%
  cor(method = "spearman", use = "complete.obs")
```

	trust	edu1	age
trust	1.000000000	-0.05900138	-0.008811693
edu1	-0.059001376	1.000000000	0.316312137
age	-0.008811693	0.31631214	1.000000000

```
# Kendall tau korelasyonu
scottish_clean %>%
  select(trust, edu1, age) %>%
  cor(method = "kendall", use = "complete.obs")
```

	trust	edu1	age
trust	1.000000000	-0.04991725	-0.007357752
edu1	-0.049917254	1.000000000	0.226994009
age	-0.007357752	0.22699401	1.000000000

```
scottish_clean %>%
  group_by(educ1) %>%
  summarise(mean_trust = mean(trust, na.rm = TRUE))
```

educ1	mean_trust
1	1.895349
2	1.860656
3	1.695455
4	1.745161
5	1.711207
6	1.707071
8	1.774193


- Güven (trust) ile eğitim (educ1) arasında pozitif bir ilişki var, ancak bu ilişki oldukça zayıf.
- Eğitim seviyesi arttıkça güven düzeyinin biraz artma eğiliminde olduğu söylenebilir, ancak bu etki istatistiksel olarak anlamlı olmayabilir.
- Güven (trust) ile yaş (age) arasında çok zayıf ve neredeyse sıfır bir ilişki var.
- Yaşın, bireylerin güven düzeyine belirgin bir etkisi olmadığı söylenebilir.

```
# Parti bağlılığına göre yaş ortalamaları
scottish_clean %>%
  group_by(pid1) %>%
  summarise(
    mean_age = mean(age, na.rm = TRUE),
    sd_age = sd(age, na.rm = TRUE),
    count = n()
  )
```

pid1	mean_age	sd_age	count
1. Conservative	60.42932	17.00600	191
2. Labour	53.38375	17.47751	443
3. SNP	51.53168	16.06740	363
NA	48.48214	18.15429	504


```
ggplot(scottish_clean, aes(x = pid1, y = age)) +
  geom_boxplot(fill = "blue", alpha = 0.7) +
  labs(title = "Parti Bağlılığına Göre Yaş Dağılımı", x = "Parti Bağlılığı", y = "Yaş")
```

Parti Bağılılığına Göre Yaş Dağılımı



```
ggplot(scottish_clean, aes(x = factor(ScotID_NoNa), y = age)) +  
  geom_boxplot(fill = "green", alpha = 0.7) +  
  labs(title = "İskoç Kimliği Algısına Göre Yaş Dağılımı", x = "İskoç Kimliği Algısı", y = "Yaş")
```

İskoç Kimliği Algısına Göre Yaş Dağılımı



```

# Parti bağlılığı ve İskoç kimliği algısı arasındaki ilişki
# Çapraz tablo
cross_table <- table(scottish_clean$pid1, scottish_clean$ScotID_NoNa)

# Satır ve sütun toplamalarını ekleme
cross_table_with_totals <- addmargins(cross_table)

# Yüzde dağılımları (satır yüzdesi)
cross_table_row_percent <- prop.table(cross_table, margin = 1) * 100

# Yüzde dağılımları (sütun yüzdesi)
cross_table_col_percent <- prop.table(cross_table, margin = 2) * 100

```

```

library(dplyr)
library(tidyr)

# Çapraz tablo
cross_table <- table(scottish_clean$pid1, scottish_clean$ScotID_NoNa)

# Çapraz tabloyu bir veri çerçevesine dönüştürme
cross_table_df <- as.data.frame(cross_table)


# Satır toplamalarını ekleme
cross_table_totals <- cross_table_df %>%
  group_by(Var1) %>%
  summarise(
    Total = sum(Freq)
  )

# Sütun toplamalarını ekleme
column_totals <- cross_table_df %>%
  group_by(Var2) %>%
  summarise(
    Total = sum(Freq)
  )

# Çapraz tabloyu görselleştirme için düzenleme
combined_table <- cross_table_df %>%
  spread(key = Var2, value = Freq) %>%
  left_join(cross_table_totals, by = c("Var1" = "Var1"))

```

```
ggplot(cross_table_df, aes(x = Var1, y = Freq, fill = Var2)) +
  geom_bar(stat = "identity", position = "dodge") +
  labs(
    title = "Parti Bağlılığı ve İskoç Kimliği Dağılımı",
    x = "Parti Bağlılığı",
    y = "Frekans",
    fill = "İskoç Kimliği"
  ) +
  theme_minimal()
```



```
# Parti bağlılığına göre ortalamalar
scottish_clean %>%
  group_by(pid1) %>%
  summarise(
    mean_leftright = mean(leftright, na.rm = TRUE),
    mean_libauth = mean(libauth, na.rm = TRUE),
    count = n()
  )
```

pid1	mean_leftright	mean_libauth	count
1. Conservative	2.753927	3.480803	191

pid1	mean_leftrigh	mean_libauth	count
2. Labour	2.217269	3.467118	443
3. SNP	2.006336	3.426446	363
NA	2.357176	3.416336	504


```
library(ggplot2)
```

```
# Parti bağıllılığına göre leftrigh kutu grafiği
```

```
ggplot(scottish_clean, aes(x = pid1, y = leftrigh)) +
```

```
  geom_boxplot(fill = "blue", alpha = 0.7) +
```

```
  labs(title = "Parti Bağıllılığı ve Sol-Sağ Eğilim", x = "Parti Bağıllılığı", y = "Sol-Sağ Eğilim")
```




```
# Parti bağıllılığına göre libauth kutu grafiği
```

```
ggplot(scottish_clean, aes(x = pid1, y = libauth)) +
```

```
  geom_boxplot(fill = "green", alpha = 0.7) +
```

```
  labs(title = "Parti Bağıllılığı ve Liberal-Otoriter Eğilim", x = "Parti Bağıllılığı", y = "Liberal-Otoriter Eğilim")
```



employmentdum (çalışma durumu: 0 = işsiz, 1 = çalışıyor) ve **edu1** (eğitim düzeyi) arasında bir ilişki olup olmadığını test edebiliriz.

```
# Satır yüzdeleri
prop.table(table(scottish_clean$employmentdum, scottish_clean$edu1), margin = 1) * 100
```

	1	2	3	4	5	6	8
0	0.000000	6.944444	12.500000	16.666667	29.166667	9.722222	25.000000
1	6.018195	16.724983	14.765570	20.853744	14.765570	6.438069	20.433870

Genel olarak işsizler, daha düşük eğitim seviyelerinde yoğunlaşıyor. İşsiz bireylerin en büyük oranı **3. Eğitim Düzeyinde (%29.2)** ve ardından **1. Eğitim Düzeyinde (%25)**.

Çalışanlar, her eğitim düzeyinde temsil edilirken, daha düşük seviyelerden yüksek seviyelere doğru azalan bir eğilim gösteriyor.

```
# Ki-kare testi
chi_test <- chisq.test(table(scottish_clean$employmentdum, scottish_clean$edu1))
```

```
Warning in chisq.test(table(scottish_clean$employmentdum,
scottish_clean$edu1)): Chi-squared approximation may be incorrect
```

chi_test

Pearson's Chi-squared test

```
data: table(scottish_clean$employmentdum, scottish_clean$edu1)
X-squared = 20.199, df = 6, p-value = 0.002552
```

- **Null Hipotez (H₀):** employmentdum (çalışma durumu) ile edu1 (eğitim düzeyi) arasında bir ilişki yoktur. Bu iki değişken birbirinden bağımsızdır.
- **Alternatif Hipotez (H₁):** employmentdum ile edu1 arasında bir ilişki vardır. Bu iki değişken bağımsız değildir.
- **p-değeri < 0.05** olduğundan, null hipotezi reddediyoruz.
- Bu, **çalışma durumu** (employmentdum) ile **eğitim düzeyi** (edu1) arasında **istatistiksel olarak anlamlı bir ilişki olduğunu** gösterir.
- Eğitim düzeyindeki değişim, bireylerin çalışma durumunu etkileyebilir veya en azından bu iki değişken bağımsız değildir.

Bağımlı değişkenin (**RefvoteDum**) diğer bağımsız değişkenler tarafından nasıl etkilendiğini modellemek için bir **lojistik regresyon modeli** kullanabiliriz. Çünkü bağımlı değişkenimiz ikili (binary: 0 = Hayır, 1 = Evet) bir değişkendir.

- Bağımsız değişkenler: **pid1** (parti bağlılığı), **edu1** (eğitim düzeyi), **age** (yaş), **sex_erkek** (cinsiyet), **libauth** (liberal-otoriter eğilim), **employmentdum** (istihdam durumu).

```
# Lojistik regresyon modeli
logit_model <- glm(RefvoteDum ~ pid1 + edu1 + age + sex_erkek + libauth + employmentdum,
                  data = scottish_clean, family = binomial)

# Modelin özetini görüntüleme
summary(logit_model)
```

Call:

```
glm(formula = RefvoteDum ~ pid1 + edu1 + age + sex_erkek + libauth +
    employmentdum, family = binomial, data = scottish_clean)
```

Coefficients:

Estimate Std. Error z value Pr(>|z|)

```

(Intercept)    -2.957878    0.688926   -4.293 1.76e-05 ***
pid12. Labour    1.932052    0.475546    4.063 4.85e-05 ***
pid13. SNP       4.052045    0.470656    8.609 < 2e-16 ***
edu1            -0.009387    0.041072   -0.229 0.819225
age             -0.003473    0.005336   -0.651 0.515182
sex_erkek        0.635837    0.166826    3.811 0.000138 ***
libauth         -0.145604    0.066163   -2.201 0.027759 *
employmentdum  -0.271127    0.383923   -0.706 0.480063
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

(Dispersion parameter for binomial family taken to be 1)

```

Null deviance: 1207.55 on 996 degrees of freedom
Residual deviance: 894.98 on 989 degrees of freedom
(504 observations deleted due to missingness)
AIC: 910.98

```

Number of Fisher Scoring iterations: 6

```

# odds ratiolar
exp(cbind(OR = coef(logit_model), confint(logit_model)))

```

Waiting for profiling to be done...

	OR	2.5 %	97.5 %
(Intercept)	0.05192899	0.01254352	0.1912776
pid12. Labour	6.90365966	2.99084627	20.0619820
pid13. SNP	57.51497776	25.25215684	166.0241006
edu1	0.99065718	0.91381622	1.0736461
age	0.99653338	0.98614957	1.0070189
sex_erkek	1.88860230	1.36379502	2.6244073
libauth	0.86450029	0.75869788	0.9837780
employmentdum	0.76251981	0.35892169	1.6260711

 Eksik veriyi medyanla doldurmak: kullanışlı ama bedelsiz değil

`scottish_clean` oluşturulurken tüm sayısal sütunlardaki eksik değerler o sütunun medyanıyla dolduruldu (`ifelse(is.na(.), median(., na.rm = TRUE), .)`). Bu, örneklem büyüklüğünü korumanın hızlı bir yoludur, ama bedelsiz değildir: **employmentdum** değişkeninin **%42.5'i eksik** — yani bu değişkende gözlemlerin neredeyse yarısı ger-

çek veri değil, medyan değeriyle (1 = Çalışıyor) doldurulmuş yapay bir değerdir. Bu, `employmentdum`'un modeldeki etkisini gerçekte olduğundan daha “sönük” (medyana doğru çekilmiş) gösterebilir. Daha sağlam bir analiz, ya bu değişkeni modelden çıkarmayı ya da çoklu değer atama (multiple imputation, ör. `mice` paketi) gibi bir yöntemi tercih ederdi — bu ileri konu, bu dersin kapsamı dışındadır, ama **hangi değişkenin ne kadar eksik olduğunu her zaman kontrol etmek** (7. modülde gördüğünüz eksik veri farkındalığının bir devamı) kapsamımız içindedir.

1. Modelin Genel Değerlendirmesi

Null deviance ile residual deviance arasındaki fark modelin açıklama gücünü gösterir. Modelin residual deviance'ındaki önemli düşüş (1207.5'ten 895.0'a), bağımsız değişkenlerin bağımlı değişkeni açıklamada etkili olduğunu gösterir.

2. Bağımsız Değişkenlerin Yorumu

Her bir bağımsız değişkenin **katsayı (Estimate)**, **p-değeri ($\Pr(>|z|)$)** ve anlamlılığına göre yorumları:

Intercept (Sabit Terim):

- **Katsayı = -2.958, $p < 0.001$**
 - Tüm bağımsız değişkenlerin etkisi sıfır olduğunda (referans kategorideki bir Conservative destekçisi, kadın, çalışmıyor, `edu1/age/libauth = 0`) “Evet” oyu verme log-odds'u negatiftir.

pid1 (Parti Bağlılığı):

- **Labour (Katsayı = 1.932, $p < 0.001$):**
 - Labour Partisi'ne bağlılık, “Evet” oyu verme olasılığını artırır.
 - Odds oranı: $e^{1.932} \approx 6.90$, yani Labour'a bağlı bireylerin “Evet” oyu verme olasılığı, Conservative'e bağlı bireylere kıyasla yaklaşık 7 kat daha fazladır.
- **SNP (Katsayı = 4.052, $p < 0.001$):**
 - SNP'ye bağlılık, “Evet” oyu verme olasılığını çok güçlü bir şekilde artırır.
 - Odds oranı: $e^{4.052} \approx 57.5$, yani SNP'ye bağlı bireylerin “Evet” oyu verme olasılığı Conservative'e bağlı bireylerden yaklaşık 58 kat daha fazladır.

edu1 (Eğitim Düzeyi):

- Katsayı = -0.0094, p = 0.819:
 - Eğitim düzeyinin “Evet” oyu verme üzerinde anlamlı bir etkisi yoktur ($p > 0.05$).

age (Yaş):

- Katsayı = -0.0035, p = 0.515:
 - Yaşın “Evet” oyu verme üzerinde anlamlı bir etkisi yoktur ($p > 0.05$).

sex_erkek (Cinsiyet):

- Katsayı = 0.636, p < 0.001:
 - Erkeklerin “Evet” oyu verme olasılığı kadınlara göre **daha yüksektir**.
 - Odds oranı: $e^{0.636} \approx 1.89$, yani erkeklerin “Evet” oyu verme olasılığı kadınlara göre yaklaşık %89 daha fazladır.

! Dikkat: yön kolayca ters yorumlanabilir

rsex değişkeni doğrudan (dummy’ye çevrilmeden) modele girseydi katsayı **negatif** (≈ -0.636) çıkardı — çünkü ham kodlamada 1=Erkek, 2=Kadın’dır ve model bunu “1 birimlik artış” (Erkek’ten Kadın’a geçiş) olarak okurdu. O durumda “negatif katsayı = erkeklerin olasılığı daha düşük” demek **yanlış** olurdu; doğrusu “kodu daha yüksek olan grubun (Kadın) olasılığı daha düşük” olurdu — ki bu tam olarak aynı sonucun (erkekler > kadınlar) farklı, kafa karıştırıcı bir ifadesidir. Açık bir sex_erkek (0/1) dummy’si bu belirsizliği tamamen ortadan kaldırır.

libauth (Liberal-Otoriter Eğilim):

- Katsayı = -0.146, p = 0.028:
 - Daha otoriter bir eğilime sahip bireylerin “Evet” oyu verme olasılığı azalır.
 - Odds oranı: $e^{-0.146} \approx 0.86$, yani otoriter eğilimdeki bireylerin “Evet” oyu verme olasılığı liberal eğilimde olanlara kıyasla %14 daha düşüktür.

employmentdum (İstihdam Durumu):

- Katsayı = -0.271, p = 0.480:
 - İstihdam durumunun “Evet” oyu verme üzerinde anlamlı bir etkisi yoktur ($p > 0.05$) — ama yukarıdaki uyarı kutusunu hatırlayın: bu değişkenin %42.5’i medyanla dolduruldu, bu yüzden “etkisiz” sonucunu ihtiyatla okuyun; gerçek veri toplansaydı sonuç değişebilirdi.

```
# Tahmin edilen olasılıkları hesaplama
predicted_prob <- predict(logit_model, type = "response")

# İlk birkaç tahmin
head(predicted_prob)
```

```
      1      2      3      4      7      8
0.22813737 0.11670208 0.18202694 0.17902510 0.09934046 0.18245958
```

- Modelimiz, her bir birey için “Evet” oyu verme olasılıklarını tahmin ediyor.
- İlk birkaç tahminde, bireylerin genellikle “Hayır” oyu verme olasılığının daha yüksek olduğunu görebiliyoruz.

Dönem Genel Tekrarı

Bu, dönemin son yeni konusu. Final sınavı dönemin tamamını kapsıyor (ağırlık 6-12. oturumlarda); aşağıdaki tablo hangi modülün hangi soruyu yanıtladığını hatırlatmak için:

Soru türü	İlgili modül(ler)
Bir değişken sayısal mı kategorik mi, veri nasıl işlenir?	2, 5
Dağılımı nasıl görselleştiririm?	3, 4
İki grup/oran arasındaki fark şans eseri mi?	10 (t-testi, ki-kare, ANOVA)
İki sürekli değişken nasıl ilişkilidir?	11 (korelasyon, basit regresyon)
Birden fazla açıklayıcı değişkeni aynı anda nasıl kullanırım?	12 (çoklu regresyon, VIF)
Bağımlı değişkenim ikili (0/1) olduğunda ne yaparım?	13 (lojistik regresyon)

Bu modülün de gösterdiği gibi, lojistik regresyon aslında `lm()` yerine `glm(family = binomial)` kullanan ve katsayıları **log-odds** olarak yorumlayan (dolayısıyla `exp()` ile odds

oranına çevrilen) bir çoklu regresyon uzantısıdır — 11. ve 12. modülde öğrendiğiniz katsayı yorumlama, VIF, standart hata ve p-değeri mantığının **tamamı** burada da geçerlidir; tek fark bağımlı değişkenin ölçek türüdür.

Sınava hazırlanırken en çok işe yarayacak alışkanlık şudur: karşınıza bir `summary()` veya `glm()` çıktısı geldiğinde önce **hangi modülün konusu olduğunu** (bağımlı değişkenin türüne bakarak) belirleyin, sonra o modülün yorumlama kalıbını uygulayın.